Transformer

Explicação matemática

versão visual e detalhada

Diagramas e cálculos de cada posição nas matrizes

O exemplo acompanhado neste material

eu estudo $\longrightarrow$ I study

Esta segunda versão acrescenta imagens, interpretação de cada operação e cálculos célula a célula à adaptação didática em português dos conceitos de *The Illustrated Transformer*, de Jay Alammar [1], com a explicação reorganizada e ampliada por fórmulas e cálculos. A saída de cada etapa é usada como entrada da etapa seguinte.

O Transformer contém um **codificador**, que constrói representações contextualizadas da entrada, e um **decodificador**, que produz a saída. A atenção relaciona posições da sequência; redes feed-forward transformam os vetores; e a codificação posicional informa a ordem dos tokens.

Como estudar. Acompanhe as dimensões das matrizes e observe de onde vêm as consultas, as chaves e os valores. As etapas 1 a 8 constroem a representação da entrada; as etapas 9 a 14 produzem a tradução; as etapas 15 e 16 calculam a perda e ilustram a atualização de um peso.

Convenções do exemplo. Os embeddings e os pesos foram escolhidos artificialmente para permitir uma passagem completa e verificável. Eles não correspondem a um tradutor treinado. Usamos ponto decimal nas matrizes. Os valores exibidos são arredondados; as contas foram verificadas com maior precisão.

Preparado para Welton. Adaptação disponibilizada sob CC BY-NC-SA 4.0, conforme a licença do texto de origem. Referências e condições de atribuição ao final.

Conteúdo

1 Definindo o tamanho do nosso Transformer **3**

2 Transformando os tokens em embeddings **5**

3 Acrescentando a codificação posicional **7**

4 Construindo consultas, chaves e valores: Q, K e V **10**

5 Calculando a autoatenção da primeira cabeça **12**

6 Calculando a segunda cabeça e reunindo os resultados **17**

7 Aplicando a conexão residual e a normalização **20**

8 Aplicando a rede feed-forward do codificador **23**

9 Preparando a entrada do decodificador **26**

10 Calculando a autoatenção mascarada **30**

11 Fazendo a atenção entre decodificador e codificador **40**

12 Concluindo o bloco do decodificador **48**

13 Transformando os vetores em probabilidades de palavras **54**

14 Gerando a tradução em sequência **58**

15 Calculando a perda com os mesmos dados **60**

16 Como essa perda modifica os pesos **62**

Referências e atribuição **66**

Dois níveis de leitura. Primeiro, acompanhe o objetivo, o diagrama e as fórmulas de cada etapa. Depois, use as tabelas de cálculos posição a posição para reproduzir cada célula numérica.

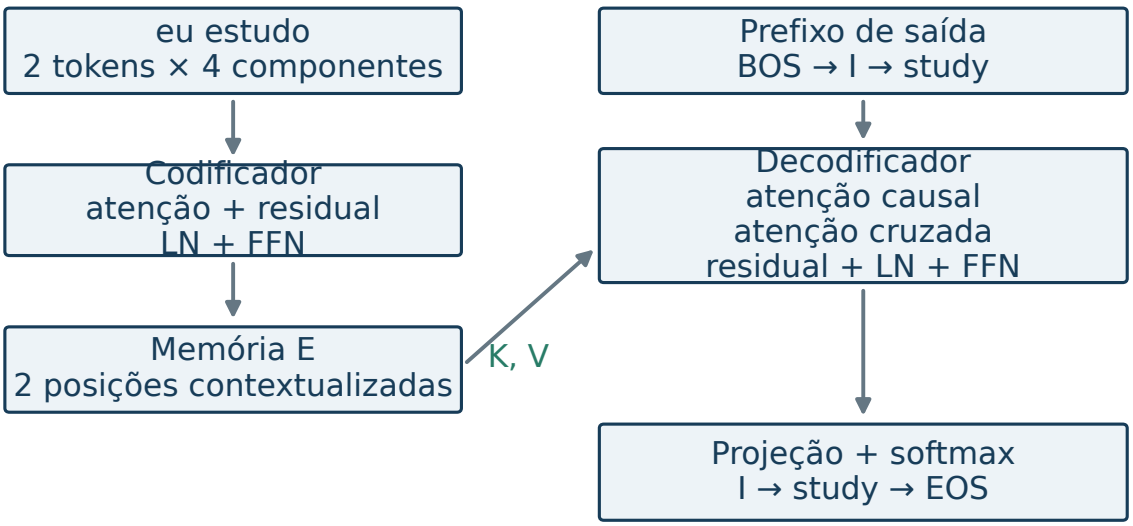
Como interpretar os números. Usamos valores arredondados nas tabelas e nos diagramas, mas calculamos os resultados com maior precisão. Todos os blocos pertencem ao mesmo exemplo; as únicas mudanças de pesos mostradas aparecem na etapa final.

Configuração fixa. Para tornar as contas reproduzíveis, usamos os seletores J_1 e J_2 em todas as atenções; $W^O = I_4$; FFN com $W_1 = I_4$, $W_2 = 0.5I_4$ e vieses zero; normalizações com $\gamma = 1$, $\beta = 0$ e $\varepsilon = 10^{-5}$. O dropout está desativado. A projeção do vocabulário é a matriz própria definida na etapa 13.

1. Definindo o tamanho do nosso Transformer

Para que serve esta etapa? Distinguir o número de tokens do número de componentes de cada vetor. As linhas acompanham posições da sequência; as colunas são coordenadas numéricas aprendidas. A quantidade de tokens pode mudar de uma frase para outra.

Dimensões. A entrada tem 2 tokens e 4 componentes: $X \in \mathbb{R}^{2\times 4}$.



Leitura da imagem. As duas rotas se encontram na atenção cruzada: as consultas vêm do decodificador; as chaves e os valores vêm da memória do codificador.

Vamos reduzir as dimensões para visualizar todas as contas. A comparação com o modelo original [2] é:

Componente	Original	Exemplo
Blocos do codificador	6	1
Blocos do decodificador	6	1
Dimensão dos vetores, d_{model}	512	4
Cabeças de atenção, h	8	2
Dimensão por cabeça, $d_k = d_v$	64	2
Dimensão interna da FFN	2.048	4

Cada token terá um vetor com quatro componentes:

$$x_i = [x_{i1}, x_{i2}, x_{i3}, x_{i4}].$$

A entrada contém dois tokens, [eu, estudo]. Portanto, a matriz que entra no codificador terá dimensão:

$$X \in \mathbb{R}^{2\times 4}.$$

Cada linha representa um token; cada coluna, uma componente de sua representação. Para simplificar, tratamos cada palavra como um token. Um tokenizador real também pode dividir palavras em partes.

Como ler os índices. As posições usadas por PE começam em 0. Já os índices de linha e coluna das tabelas começam em 1. Portanto, a posição 0 de eu aparece na linha 1 da matriz; a posição 1 de estudo aparece na linha 2.

Uma multiplicação não tem sempre o mesmo objetivo. Em XJ_r, projetamos as componentes. Em $QK^\top$, comparamos posições. Em AV, combinamos valores. Em DW_{vocab}, calculamos escores de tokens. As dimensões e o papel dos operandos mostram o que cada operação faz.

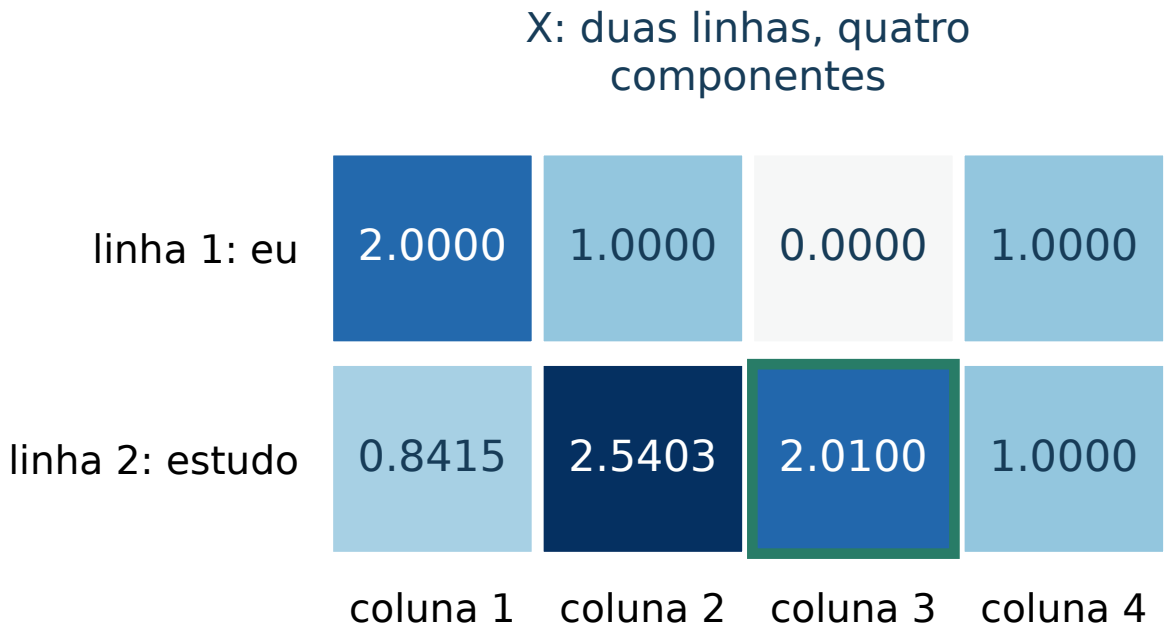
Roteiro das dimensões

Operação	Objetivo	Formato no exemplo
XJ_r	Projetar as componentes para uma cabeça.	$2 \times 4 \to 2 \times 2$
$QK^\top$	Comparar todos os pares de posições.	2×2 escores
softmax(S)	Distribuir pesos por linha.	Mesmo formato de S
AV	Misturar os valores consultados.	2×2 por cabeça
Concatenação	Reunir as saídas das cabeças.	$2 \times 2 + 2 \times 2 \to 2 \times 4$
LN e residual	Ajustar escala e combinar representações.	Mesmo formato
DW_{vocab}	Produzir escores para o vocabulário.	$3 \times 4 \to 3 \times 3$

2. Transformando os tokens em embeddings

Para que serve esta etapa? Converter a identidade de cada token em um vetor que possa participar de operações numéricas. Um embedding é uma consulta a uma tabela de parâmetros. Durante o treinamento, os vetores podem aprender relações úteis para a tarefa; neste exemplo, seus valores são artificiais.

Dimensões. Cada token é representado por 4 componentes. Multiplicar o embedding por 2 muda sua escala, preservando as dimensões.



Leitura da imagem. A célula destacada é X[2,3] = 2.0100: segunda linha, terceira coluna. Os índices das matrizes começam em 1; a codificação posicional usa posições 0, 1, 2.

Um embedding é um vetor associado a um token. Escolheremos:

Token de entrada	**Embedding** $e(\textbf{token})$
eu	$[1, 0, 0, 0]$
estudo	$[0, 1, 1, 0]$

Esses números são parâmetros. Em um treinamento real, seus valores são ajustados pelo processo de aprendizagem.

Antes de acrescentar a posição, aplicamos a escala usada no Transformer original:

$$\tilde{e}_i = \sqrt{d_{\text{model}}}\, e_i.$$

Como $\sqrt{4} = 2$, obtemos:

$$\tilde{e}_{\text{eu}} = [2, 0, 0, 0], \qquad \tilde{e}_{\text{estudo}} = [0, 2, 2, 0].$$

Ainda falta informar qual token vem primeiro e qual vem depois.

Interpretação das componentes. As quatro colunas não são rótulos fixos como sujeito, verbo ou tempo. São coordenadas de uma representação numérica. As relações úteis surgem do treinamento e do uso dessas coordenadas em conjunto.

Cálculos posição a posição

Nas tabelas, (i, j) indica linha i e coluna j. Os resultados usam os valores completos; pequenas diferenças ao refazer as contas com os números impressos decorrem do arredondamento.

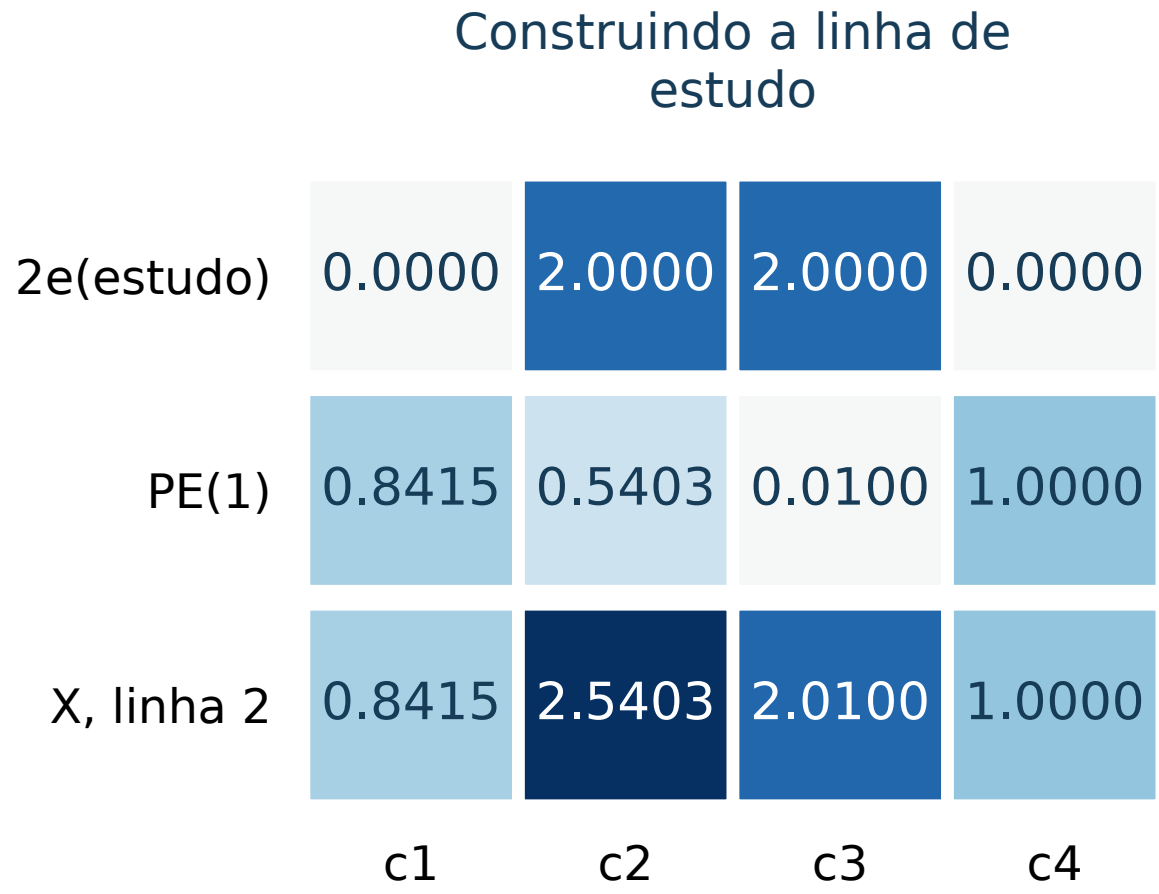
Escala de cada célula do embedding de entrada

Posição	Conta	Resultado
(1,1)	$2.0 \times (1.0000)$	2.0000
(1,2)	$2.0 \times (0.0000)$	0.0000
(1,3)	$2.0 \times (0.0000)$	0.0000
(1,4)	$2.0 \times (0.0000)$	0.0000
(2,1)	$2.0 \times (0.0000)$	0.0000
(2,2)	$2.0 \times (1.0000)$	2.0000
(2,3)	$2.0 \times (1.0000)$	2.0000
(2,4)	$2.0 \times (0.0000)$	0.0000

3. Acrescentando a codificação posicional

Para que serve esta etapa? Acrescentar informação sobre a ordem das palavras. O vetor posicional é somado ao embedding, componente a componente. Assim, a posição pode influenciar as comparações de atenção feitas depois.

Dimensões. $(2 \times 4) + (2 \times 4) \to 2 \times 4$. A soma mantém as quatro componentes de cada token.



Leitura da imagem. Para a posição de estudo, cada célula da última linha é a soma das duas células acima dela. A soma das matrizes completas preserva o formato 2×4.

Usaremos a codificação senoidal [2]:

$$PE(pos, 2i) = \sin\left(\frac{pos}{10000^{2i/d_{\text{model}}}}\right),$$
$$PE(pos, 2i+1) = \cos\left(\frac{pos}{10000^{2i/d_{\text{model}}}}\right).$$

Para quatro componentes, a expressão fica:

$$PE(pos) = \left[\sin(pos), \cos(pos), \sin\left(\frac{pos}{100}\right), \cos\left(\frac{pos}{100}\right)\right].$$

Os argumentos estão em radianos e as posições começam em zero. Assim:

$$PE(0) = [0, 1, 0, 1],$$
$$PE(1) \approx [0.8415, 0.5403, 0.0100, 0.99995].$$

A entrada efetiva é a soma do embedding escalado com a posição:

$$x_i = 2e_i + PE(i).$$

Para “eu”:

$$x_{\text{eu}} = [2, 0, 0, 0] + [0, 1, 0, 1] = [2, 1, 0, 1].$$

Para “estudo”:

$$\begin{aligned} x_{\text{estudo}} &\approx [0, 2, 2, 0] + [0.8415, 0.5403, 0.0100, 0.99995] \\ &\approx [0.8415, 2.5403, 2.0100, 0.99995]. \end{aligned}$$

A matriz de entrada está pronta:

$$\boxed{X \approx \begin{bmatrix} 2.0000 & 1.0000 & 0.0000 & 1.0000 \\ 0.8415 & 2.5403 & 2.0100 & 0.99995 \end{bmatrix}}$$

É essa matriz que seguirá para a atenção.

Somar e concatenar são operações diferentes. Aqui, a soma combina duas informações em quatro componentes. A concatenação das cabeças, apresentada depois, coloca componentes lado a lado. Observe o formato da saída para acompanhar essa diferença.

Cálculos posição a posição

Nas tabelas, (i, j) indica linha i e coluna j. Os resultados usam os valores completos; pequenas diferenças ao refazer as contas com os números impressos decorrem do arredondamento.

Cada componente da codificação posicional

Posição	Conta	Resultado
(1,1)	$\sin\left(\frac{0}{1}\right)$	0.00000
(1,2)	$\cos\left(\frac{0}{1}\right)$	1.00000
(1,3)	$\sin\left(\frac{0}{100}\right)$	0.00000
(1,4)	$\cos\left(\frac{0}{100}\right)$	1.00000
(2,1)	$\sin\left(\frac{1}{1}\right)$	0.84147
(2,2)	$\cos\left(\frac{1}{1}\right)$	0.54030

Continua na próxima página.

Posição	Conta (continuação)	Resultado
(2,3)	$\sin\left(\frac{1}{100}\right)$	0.01000
(2,4)	$\cos\left(\frac{1}{100}\right)$	0.99995

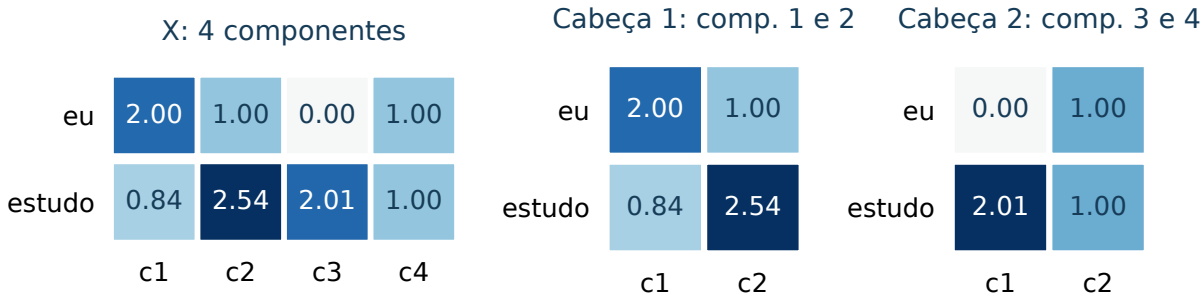
Embedding escalado + posição = X

Posição	Conta	Resultado
(1,1)	$2.00000 + (0.00000)$	2.00000
(1,2)	$0.00000 + (1.00000)$	1.00000
(1,3)	$0.00000 + (0.00000)$	0.00000
(1,4)	$0.00000 + (1.00000)$	1.00000
(2,1)	$0.00000 + (0.84147)$	0.84147
(2,2)	$2.00000 + (0.54030)$	2.54030
(2,3)	$2.00000 + (0.01000)$	2.01000
(2,4)	$0.00000 + (0.99995)$	0.99995

4. Construindo consultas, chaves e valores: Q, K e V

Para que serve esta etapa? Construir três representações com funções distintas: a consulta participa da busca, a chave da comparação e o valor da informação misturada. As matrizes de projeção aprendem quais combinações de características serão úteis a cada cabeça.

Dimensões. Em cada cabeça, $(2 \times 4)(4 \times 2) \to 2 \times 2$: cada vetor é projetado de 4 para 2 componentes. As duas posições são preservadas.



Leitura da imagem. Neste exemplo, J1 e J2 reduzem cada vetor de 4 para 2 componentes. As projeções são iguais para Q, K e V apenas para simplificar a aritmética.

A atenção usa três projeções lineares:

$$Q = XW^Q, \qquad K = XW^K, \qquad V = XW^V.$$

Projeção	Papel matemático
Consulta, Q	Participa da comparação feita por uma posição.
Chave, K	Participa da comparação com as posições consultadas.
Valor, V	Contém os vetores combinados pelos pesos de atenção.

O peso depende da comparação entre consulta e chave. A saída resulta da combinação dos valores.

Para simplificar as contas, escolheremos:

$$J_1 = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \\ 0 & 0 \end{bmatrix}, \qquad J_2 = \begin{bmatrix} 0 & 0 \\ 0 & 0 \\ 1 & 0 \\ 0 & 1 \end{bmatrix}.$$

Na primeira cabeça, $W_1^Q = W_1^K = W_1^V = J_1$. Na segunda, $W_2^Q = W_2^K = W_2^V = J_2$.

A primeira cabeça seleciona as duas primeiras componentes; a segunda seleciona as duas últimas. A igualdade entre as projeções de consulta, chave e valor é uma escolha didática. Em geral, são matrizes aprendidas separadamente.

Para a primeira cabeça:

$$Q_1 = K_1 = V_1 \approx \begin{bmatrix} 2.0000 & 1.0000 \\ 0.8415 & 2.5403 \end{bmatrix}.$$

Para a segunda:

$$Q_2 = K_2 = V_2 \approx \begin{bmatrix} 0.0000 & 1.0000 \\ 2.0100 & 0.99995 \end{bmatrix}.$$

O que significa reduzir a dimensão? Cada vetor de quatro números origina um vetor de dois números para a cabeça. Isso diminui o tamanho das comparações feitas por cabeça. Em um modelo treinado, a projeção pode combinar todas as quatro componentes em cada saída; os seletores J_1 e J_2 foram escolhidos para deixar as contas transparentes.

Cálculos posição a posição

Nas tabelas, (i, j) indica linha i e coluna j. Os resultados usam os valores completos; pequenas diferenças ao refazer as contas com os números impressos decorrem do arredondamento.

Como $Q_r = K_r = V_r = XJ_r$ neste exemplo, cada conta abaixo determina a célula correspondente nas três matrizes. Os quatro termos exibem explicitamente o produto pela coluna de J_r.

Projeções Q_r, K_r e V_r - cabeça 1

Posição	Conta	Resultado
(1,1)	$(2.0000) \times 1 + (1.0000) \times 0$ $+(0.0000) \times 0 + (1.0000) \times 0$	2.0000
(1,2)	$(2.0000) \times 0 + (1.0000) \times 1$ $+(0.0000) \times 0 + (1.0000) \times 0$	1.0000
(2,1)	$(0.8415) \times 1 + (2.5403) \times 0$ $+(2.0100) \times 0 + (1.0000) \times 0$	0.8415
(2,2)	$(0.8415) \times 0 + (2.5403) \times 1$ $+(2.0100) \times 0 + (1.0000) \times 0$	2.5403

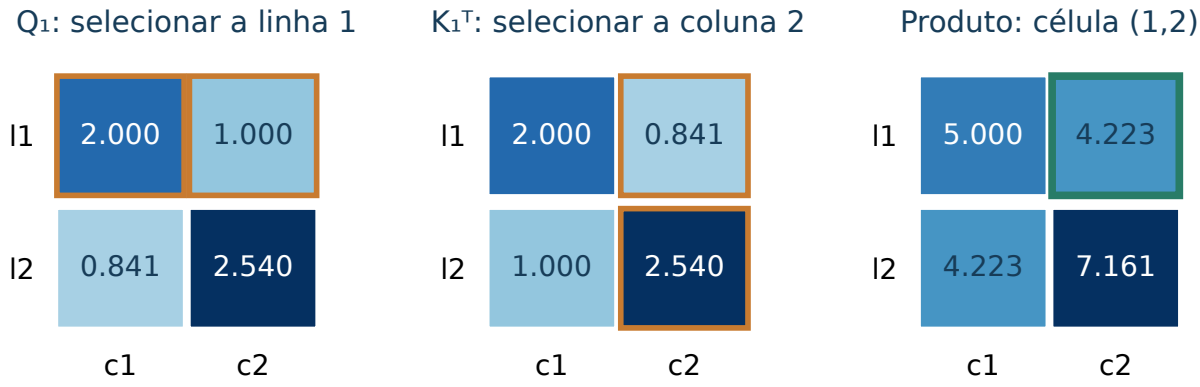
Projeções Q_r, K_r e V_r - cabeça 2

Posição	Conta	Resultado
(1,1)	$(2.0000) \times 0 + (1.0000) \times 0$ $+(0.0000) \times 1 + (1.0000) \times 0$	0.0000
(1,2)	$(2.0000) \times 0 + (1.0000) \times 0$ $+(0.0000) \times 0 + (1.0000) \times 1$	1.0000
(2,1)	$(0.8415) \times 0 + (2.5403) \times 0$ $+(2.0100) \times 1 + (1.0000) \times 0$	2.0100
(2,2)	$(0.8415) \times 0 + (2.5403) \times 0$ $+(2.0100) \times 0 + (1.0000) \times 1$	1.0000

5. Calculando a autoatenção da primeira cabeça

Para que serve esta etapa? Calcular quanto cada posição contribuirá para a nova representação de outra posição. O produto $QK^\top$ compara consultas com chaves; a divisão por $\sqrt{2}$ controla a escala; o softmax transforma os escores em pesos positivos cuja soma, por linha, é 1. A multiplicação por V efetua a mistura.

Dimensões. $QK^\top : (2 \times 2)(2 \times 2) \to 2 \times 2$ contém pares de posições. Depois, $AV : (2 \times 2)(2 \times 2) \to 2 \times 2$ contém vetores de saída.



Leitura da imagem. Para preencher uma célula do produto, multiplicamos a linha destacada pela coluna destacada e somamos os produtos.

A expressão central é:

$$\boxed{\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right)V.}$$

O softmax é aplicado separadamente em cada linha. Primeiro, calculamos os produtos entre consultas e chaves:

$$Q_1 K_1^\top \approx \begin{bmatrix} 5.0000 & 4.2232 \\ 4.2232 & 7.1612 \end{bmatrix}.$$

Por exemplo, a comparação da consulta de “eu” com a chave de “estudo” é:

$$\begin{aligned}[2, 1] \cdot [0.8415, 2.5403] &= 2(0.8415) + 1(2.5403) \\ &\approx 4.2232.\end{aligned}$$

Dividimos os escores por $\sqrt{d_k} = \sqrt{2}$:

$$S_1 = \frac{Q_1 K_1^\top}{\sqrt{2}} \approx \begin{bmatrix} 3.5355 & 2.9863 \\ 2.9863 & 5.0637 \end{bmatrix}.$$

Essa escala ajuda a controlar a magnitude dos escores. Sob hipóteses de independência, média zero e variância unitária das componentes, a variância do produto escalar cresce com d_k; dividir por $\sqrt{d_k}$ compensa esse crescimento.

Agora aplicamos:

$$\text{softmax}(s)_j = \frac{e^{s_j}}{\sum_r e^{s_r}}.$$

Na primeira linha:

$$a_{11} = \frac{e^{3.5355}}{e^{3.5355} + e^{2.9863}} \approx 0.6340, \qquad a_{12} \approx 0.3660.$$

A matriz completa de pesos é:

$$A_1 \approx \begin{bmatrix} 0.6340 & 0.3660 \\ 0.1113 & 0.8887 \end{bmatrix}.$$

Representação calculada	Peso sobre eu	Peso sobre estudo
eu	63,40%	36,60%
estudo	11,13%	88,87%

Por fim, combinamos os valores:

$$Z_1 = A_1 V_1.$$

Para a posição de "eu":

$$\begin{aligned} z_{\text{eu}}^{(1)} &= 0.6340[2, 1] + 0.3660[0.8415, 2.5403] \\ &\approx [1.5759, 1.5638]. \end{aligned}$$

Para as duas posições:

$$\boxed{Z_1 \approx \begin{bmatrix} 1.5759 & 1.5638 \\ 0.9704 & 2.3689 \end{bmatrix}.}$$

A representação de cada posição passou a incorporar uma combinação das informações das duas posições.

Como interpretar o softmax. Os escores podem ser negativos ou positivos e não precisam somar 1. O softmax exponencia esses números e divide cada exponencial pela soma das exponenciais da mesma linha:

$$\alpha_{ij} = \frac{\exp(s_{ij})}{\sum_r \exp(s_{ir})}.$$

Com escores finitos, os pesos ficam estritamente entre 0 e 1 e a linha soma 1, ou 100%. A exponenciação faz as diferenças entre escores influenciarem a concentração da distribuição.

O que o percentual representa? Na primeira cabeça, a linha de eu usa 63.40% do vetor de valor da posição de eu e 36.60% do vetor da posição de estudo. Esses percentuais quantificam a mistura dos vetores nesta operação. Eles não medem literalmente uma fração do significado de uma palavra; neste exemplo, os pesos foram montados artificialmente.

Escores de atenção e probabilidades de saída. O softmax desta etapa distribui pesos entre posições consultadas. O softmax final, da etapa 13, distribuirá probabilidades entre tokens do vocabulário.

Cálculos posição a posição

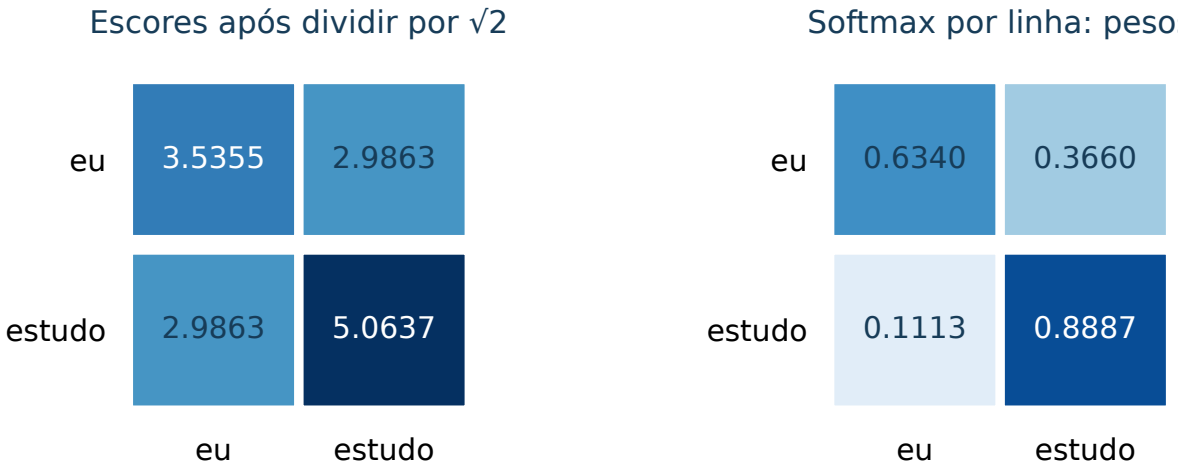
Nas tabelas, (i, j) indica linha i e coluna j. Os resultados usam os valores completos; pequenas diferenças ao refazer as contas com os números impressos decorrem do arredondamento.

Produto $Q_1 K_1^\top$: todos os pares de posições

Posição	Conta	Resultado
(1,1)	$(2.0000)(2.0000) + (1.0000)(1.0000)$	5.0000
(1,2)	$(2.0000)(0.8415) + (1.0000)(2.5403)$	4.2232
(2,1)	$(0.8415)(2.0000) + (2.5403)(1.0000)$	4.2232
(2,2)	$(0.8415)(0.8415) + (2.5403)(2.5403)$	7.1612

Divisão dos escores por $\sqrt{2}$

Posição	Conta	Resultado
(1,1)	$\frac{5.0000}{\sqrt{2}}$	3.5355
(1,2)	$\frac{4.2232}{\sqrt{2}}$	2.9863
(2,1)	$\frac{4.2232}{\sqrt{2}}$	2.9863
(2,2)	$\frac{7.1612}{\sqrt{2}}$	5.0637



Leitura da imagem. A primeira linha vira 63.40% e 36.60%; a segunda, 11.13% e 88.87%. Cada linha define uma mistura própria e soma 100%.

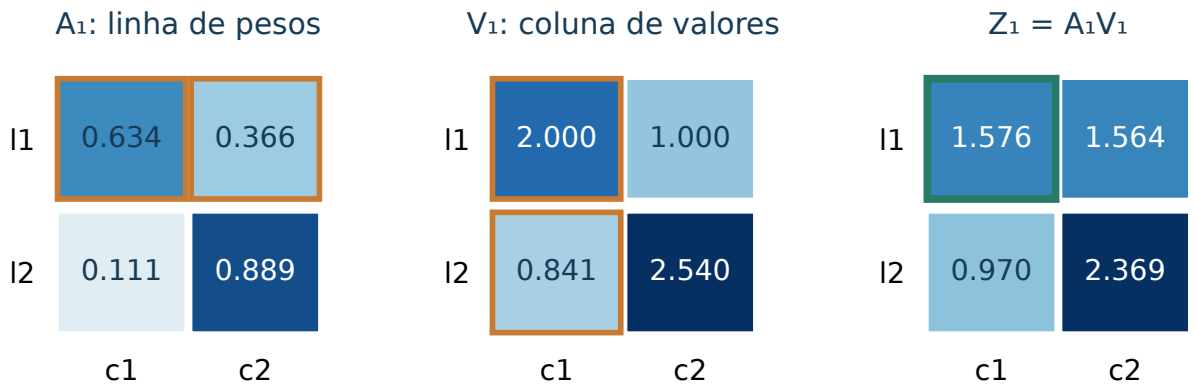
Para cada linha i, definimos $N_i = \sum_j e^{S_{ij}}$. A primeira tabela calcula esse denominador; a seguinte calcula cada peso.

Softmax da cabeça 1 - denominador de cada linha

Posição	Conta	N_i
linha 1	$e^{3.5355} + e^{2.9863}$	54.1253
linha 2	$e^{2.9863} + e^{5.0637}$	177.9929

Softmax da cabeça 1 - cada peso

Posição	Conta	Resultado
(1,1)	$\frac{e^{3.5355}}{54.1253}$	0.6340
(1,2)	$\frac{e^{2.9863}}{54.1253}$	0.3660
(2,1)	$\frac{e^{2.9863}}{177.9929}$	0.1113
(2,2)	$\frac{e^{5.0637}}{177.9929}$	0.8887



Leitura da imagem. A saída é uma média ponderada dos vetores de valor. A primeira componente do novo vetor de eu mistura as primeiras componentes dos dois valores.

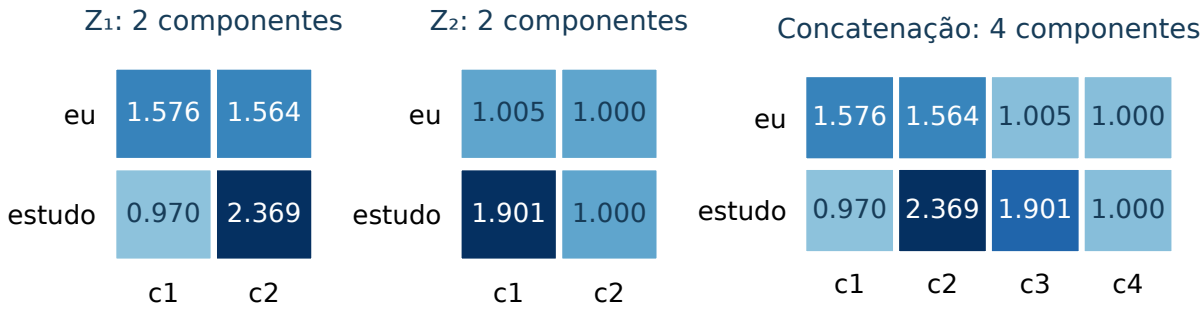
Produto A_1V_1: cada componente de Z_1

Posição	Conta	Resultado
(1,1)	$(0.6340)(2.0000) + (0.3660)(0.8415)$	1.5759
(1,2)	$(0.6340)(1.0000) + (0.3660)(2.5403)$	1.5638
(2,1)	$(0.1113)(2.0000) + (0.8887)(0.8415)$	0.9704
(2,2)	$(0.1113)(1.0000) + (0.8887)(2.5403)$	2.3689

6. Calculando a segunda cabeça e reunindo os resultados

Para que serve esta etapa? Permitir que duas projeções produzam combinações de informação diferentes. Concatenar reúne as componentes calculadas pelas cabeças. A projeção de saída pode aprender a recombiná-las; aqui ela é a identidade.

Dimensões. $Z_1, Z_2 \in \mathbb{R}^{2\times 2}$. A concatenação produz 2×4; multiplicar por I_4 mantém 2×4.



Leitura da imagem. Concatenar coloca as duas saídas lado a lado: as primeiras duas colunas vêm de Z1; as outras duas vêm de Z2. A matriz identidade WO mantém esses valores.

Repetimos a operação usando Q_2, K_2 e V_2:

$$S_2 = \frac{Q_2 K_2^\top}{\sqrt{2}} \approx \begin{bmatrix} 0.7071 & 0.7071 \\ 0.7071 & 3.5638 \end{bmatrix}.$$

$$A_2 = \text{softmax}(S_2) \approx \begin{bmatrix} 0.5000 & 0.5000 \\ 0.0543 & 0.9457 \end{bmatrix}.$$

$$Z_2 = A_2 V_2 \approx \begin{bmatrix} 1.0050 & 1.0000 \\ 1.9008 & 1.0000 \end{bmatrix}.$$

As cabeças produziram combinações diferentes porque trabalharam com projeções diferentes.

A atenção com múltiplas cabeças reúne esses resultados:

$$Z = \text{Concat}(Z_1, Z_2) W^O.$$

Escolheremos $W^O = I_4$, a matriz identidade. Portanto:

$$\boxed{Z \approx \begin{bmatrix} 1.5759 & 1.5638 & 1.0050 & 1.0000 \\ 0.9704 & 2.3689 & 1.9008 & 1.0000 \end{bmatrix}.}$$

A saída continua com dimensão 2×4.

Por que duas cabeças? Cada uma pode aprender comparações e valores diferentes. Isso permite construir a representação usando mais de uma combinação de informações. O treinamento determina o uso efetivo de cada cabeça.

Cálculos posição a posição

Nas tabelas, (i, j) indica linha i e coluna j. Os resultados usam os valores completos; pequenas diferenças ao refazer as contas com os números impressos decorrem do arredondamento.

Produto $Q_2 K_2^\top$

Posição	Conta	Resultado
(1,1)	$(0.0000)(0.0000) + (1.0000)(1.0000)$	1.0000
(1,2)	$(0.0000)(2.0100) + (1.0000)(1.0000)$	1.0000
(2,1)	$(2.0100)(0.0000) + (1.0000)(1.0000)$	1.0000
(2,2)	$(2.0100)(2.0100) + (1.0000)(1.0000)$	5.0400

Divisão dos escores da cabeça 2

Posição	Conta	Resultado
(1,1)	$\frac{1.0000}{\sqrt{2}}$	0.7071
(1,2)	$\frac{1.0000}{\sqrt{2}}$	0.7071
(2,1)	$\frac{1.0000}{\sqrt{2}}$	0.7071
(2,2)	$\frac{5.0400}{\sqrt{2}}$	3.5638

Softmax da cabeça 2 - denominador de cada linha

Posição	Conta	N_i
linha 1	$e^{0.7071} + e^{0.7071}$	4.0562
linha 2	$e^{0.7071} + e^{3.5638}$	37.3257

Softmax da cabeça 2 - cada peso

Posição	Conta	Resultado
(1,1)	$\frac{e^{0.7071}}{4.0562}$	0.5000
(1,2)	$\frac{e^{0.7071}}{4.0562}$	0.5000
(2,1)	$\frac{e^{0.7071}}{37.3257}$	0.0543
(2,2)	$\frac{e^{3.5638}}{37.3257}$	0.9457

Produto A_2V_2: cada componente de Z_2

Posição	Conta	Resultado
(1,1)	$(0.5000)(0.0000) + (0.5000)(2.0100)$	1.0050
(1,2)	$(0.5000)(1.0000) + (0.5000)(1.0000)$	1.0000
(2,1)	$(0.0543)(0.0000) + (0.9457)(2.0100)$	1.9008
(2,2)	$(0.0543)(1.0000) + (0.9457)(1.0000)$	1.0000

Localizando cada célula na concatenação

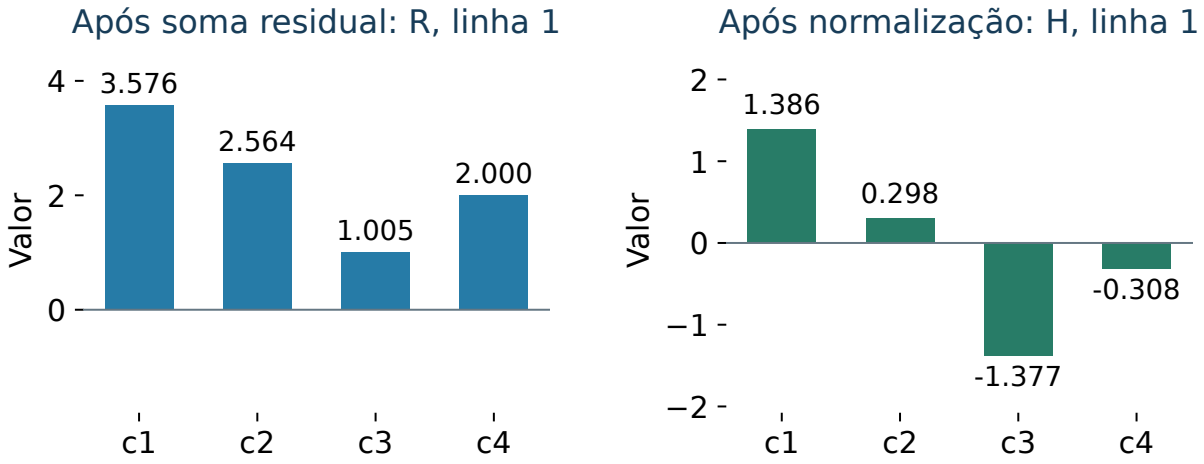
Cada célula é copiada da cabeça indicada; concatenar reorganiza as colunas.

Posição	Conta	Resultado
(1,1)	$Z^{(1)}_{1,1}$	1.5759
(1,2)	$Z^{(1)}_{1,2}$	1.5638
(1,3)	$Z^{(2)}_{1,1}$	1.0050
(1,4)	$Z^{(2)}_{1,2}$	1.0000
(2,1)	$Z^{(1)}_{2,1}$	0.9704
(2,2)	$Z^{(1)}_{2,2}$	2.3689
(2,3)	$Z^{(2)}_{2,1}$	1.9008
(2,4)	$Z^{(2)}_{2,2}$	1.0000

7. Aplicando a conexão residual e a normalização

Para que serve esta etapa? Combinar a representação anterior com a informação produzida pela atenção e ajustar a escala numérica de cada vetor. A soma residual fornece um caminho direto entre a entrada e a saída da subcamada. A normalização usa média e variância calculadas dentro de cada token.

Dimensões. A soma residual e a normalização preservam 2×4. A normalização pode produzir valores negativos; ela não gera probabilidades.



Leitura da imagem. A normalização muda a escala das quatro componentes de um token. A quantidade de componentes permanece igual e podem surgir valores negativos.

A conexão residual soma a entrada da subcamada à sua saída:

$$R = X + Z \approx \begin{bmatrix} 3.5759 & 2.5638 & 1.0050 & 2.0000 \\ 1.8119 & 4.9092 & 3.9108 & 1.9999 \end{bmatrix}.$$

Depois aplicamos a normalização por camada [3]:

$$\mathrm{LN}(u) = \gamma \odot \frac{u - \mu}{\sqrt{\sigma^2 + \varepsilon}} + \beta.$$

Para cada vetor com quatro componentes:

$$\mu = \frac{1}{4}\sum_{j=1}^{4} u_j, \qquad \sigma^2 = \frac{1}{4}\sum_{j=1}^{4}(u_j - \mu)^2.$$

A média e a variância são calculadas dentro do vetor de cada token.

Em todas as normalizações deste exemplo, usaremos:

$$\gamma = [1, 1, 1, 1], \quad \beta = [0, 0, 0, 0], \quad \varepsilon = 10^{-5}.$$

Na primeira linha de R:

$$\mu \approx 2.2862, \qquad \sigma^2 \approx 0.8660.$$

Por exemplo, a primeira componente normalizada é:

$$\frac{3.5759 - 2.2862}{\sqrt{0.8660 + 0.00001}} \approx 1.3860.$$

Aplicando a operação às duas linhas:

$$\boxed{H = \mathrm{LN}(X + Z) \approx \begin{bmatrix} 1.3860 & 0.2983 & -1.3768 & -0.3075 \\ -1.0334 & 1.3445 & 0.5780 & -0.8891 \end{bmatrix}.}$$

Esse é o resultado da primeira subcamada do codificador.

Por que a dimensão deve coincidir na soma residual? A célula (i, j) da entrada é somada à célula (i, j) da saída da subcamada. Por isso, as duas matrizes precisam ter o mesmo formato. A projeção W^O da atenção ajuda a garantir a dimensão necessária.

O significado de γ e β. A normalização pode aprender uma escala γ e um deslocamento β por componente. Fixamos $\gamma = 1$ e $\beta = 0$ para mostrar apenas a centralização e a divisão pelo desvio-padrão.

Cálculos posição a posição

Nas tabelas, (i, j) indica linha i e coluna j. Os resultados usam os valores completos; pequenas diferenças ao refazer as contas com os números impressos decorrem do arredondamento.

Conexão residual $R = X + Z$

Posição	Conta	Resultado
(1,1)	$2.0000 + (1.5759)$	3.5759
(1,2)	$1.0000 + (1.5638)$	2.5638
(1,3)	$0.0000 + (1.0050)$	1.0050
(1,4)	$1.0000 + (1.0000)$	2.0000
(2,1)	$0.8415 + (0.9704)$	1.8119
(2,2)	$2.5403 + (2.3689)$	4.9092
(2,3)	$2.0100 + (1.9008)$	3.9108
(2,4)	$1.0000 + (1.0000)$	1.9999

Normalização de R para obter H - média e variância por token

Posição	Conta	Resultado
média 1	$\frac{(3.5759)+(2.5638)+(1.0050)+(2.0000)}{4}$	2.286175
var. 1	$(3.5759-(2.286175))^2+(2.5638-(2.286175))^2$ $+(1.0050-(2.286175))^2+(2.0000-(2.286175))^2$ Dividir a soma acima por 4.	0.865981
média 2	$\frac{(1.8119)+(4.9092)+(3.9108)+(1.9999)}{4}$	3.157936
var. 2	$(1.8119-(3.157936))^2+(4.9092-(3.157936))^2$ $+(3.9108-(3.157936))^2+(1.9999-(3.157936))^2$ Dividir a soma acima por 4.	1.696608

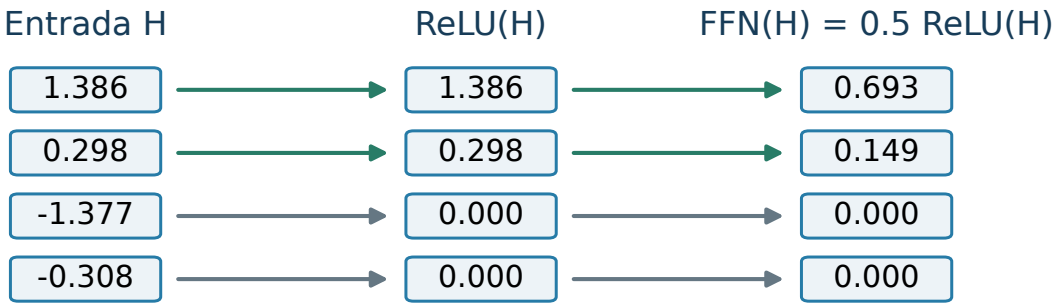
Normalização de R para obter H - cada componente normalizada

Posição	Conta	Resultado
(1,1)	$\frac{3.5759-(2.286175)}{\sqrt{0.865981+0.00001}}$	1.3860
(1,2)	$\frac{2.5638-(2.286175)}{\sqrt{0.865981+0.00001}}$	0.2983
(1,3)	$\frac{1.0050-(2.286175)}{\sqrt{0.865981+0.00001}}$	−1.3768
(1,4)	$\frac{2.0000-(2.286175)}{\sqrt{0.865981+0.00001}}$	−0.3075
(2,1)	$\frac{1.8119-(3.157936)}{\sqrt{1.696608+0.00001}}$	−1.0334
(2,2)	$\frac{4.9092-(3.157936)}{\sqrt{1.696608+0.00001}}$	1.3445
(2,3)	$\frac{3.9108-(3.157936)}{\sqrt{1.696608+0.00001}}$	0.5780
(2,4)	$\frac{1.9999-(3.157936)}{\sqrt{1.696608+0.00001}}$	−0.8891

8. Aplicando a rede feed-forward do codificador

Para que serve esta etapa? Transformar, de forma não linear, as componentes de cada token. A atenção misturou informações entre posições; a FFN atua separadamente em cada linha, usando os mesmos pesos para todas as posições.

Dimensões. No exemplo: $4 \to 4 \to 4$ componentes. No Transformer original: $512 \to 2048 \to 512$. A camada interna pode ampliar a representação.



Leitura da imagem. Com os pesos escolhidos, a ReLU zera as componentes negativas e preserva as positivas; a segunda transformação multiplica as positivas por 0.5.

A rede feed-forward tem a forma:

$$\text{FFN}(u) = \text{ReLU}(uW_1 + b_1)W_2 + b_2, \qquad \text{ReLU}(a) = \max(0, a).$$

Escolheremos, tanto no codificador quanto no decodificador:

$$W_1 = I_4, \qquad W_2 = 0.5I_4, \qquad b_1 = b_2 = 0.$$

Portanto:

$$\text{FFN}(u) = 0.5\,\text{ReLU}(u).$$

Aplicando a H:

$$F = \text{FFN}(H) \approx \begin{bmatrix} 0.6930 & 0.1492 & 0 & 0 \\ 0 & 0.6722 & 0.2890 & 0 \end{bmatrix}.$$

Novamente, usamos soma residual e normalização:

$$E = \text{LN}(H + F).$$

O resultado é:

$$\boxed{E \approx \begin{bmatrix} 1.4847 & 0.1883 & -1.2613 & -0.4117 \\ -1.0033 & 1.3993 & 0.4937 & -0.8896 \end{bmatrix}.}$$

Essa é a saída final do nosso codificador. As duas linhas continuam associadas às posições de “eu” e “estudo”, agora com representações contextualizadas.

A atenção combinou informações entre posições. A FFN aplicou a mesma transformação, separadamente, a cada posição.

De onde vem a não linearidade? A ReLU aplica $\max(0, u)$ a cada componente. Os pesos identidade do exemplo tornam a operação especialmente simples. Em uma FFN treinada, a primeira transformação combina componentes antes da ReLU, e a segunda volta à dimensão necessária para a soma residual.

Cálculos posição a posição

Nas tabelas, (i, j) indica linha i e coluna j. Os resultados usam os valores completos; pequenas diferenças ao refazer as contas com os números impressos decorrem do arredondamento.

Cada componente de $F = 0.5\,\mathrm{ReLU}(H)$

Posição	Conta	Resultado
(1,1)	$0.5 \times \max(0, 1.3860)$	0.6930
(1,2)	$0.5 \times \max(0, 0.2983)$	0.1492
(1,3)	$0.5 \times \max(0, -1.3768)$	0.0000
(1,4)	$0.5 \times \max(0, -0.3075)$	0.0000
(2,1)	$0.5 \times \max(0, -1.0334)$	0.0000
(2,2)	$0.5 \times \max(0, 1.3445)$	0.6722
(2,3)	$0.5 \times \max(0, 0.5780)$	0.2890
(2,4)	$0.5 \times \max(0, -0.8891)$	0.0000

Conexão residual $G = H + F$

Posição	Conta	Resultado
(1,1)	$1.3860 + (0.6930)$	2.0789
(1,2)	$0.2983 + (0.1492)$	0.4475
(1,3)	$-1.3768 + (0.0000)$	-1.3768
(1,4)	$-0.3075 + (0.0000)$	-0.3075
(2,1)	$-1.0334 + (0.0000)$	-1.0334
(2,2)	$1.3445 + (0.6722)$	2.0167
(2,3)	$0.5780 + (0.2890)$	0.8670
(2,4)	$-0.8891 + (0.0000)$	-0.8891

Normalização de G para obter a memória E - média e variância por token

Posição	Conta	Resultado
média 1	$\frac{(2.0789)+(0.4475)+(-1.3768)+(-0.3075)}{4}$	0.210538
var. 1	$(2.0789-(0.210538))^2+(0.4475-(0.210538))^2$ $+(-1.3768-(0.210538))^2+(-0.3075-(0.210538))^2$ Dividir a soma acima por 4.	1.583757
média 2	$\frac{(-1.0334)+(2.0167)+(0.8670)+(-0.8891)}{4}$	0.240306
var. 2	$(-1.0334-(0.240306))^2+(2.0167-(0.240306))^2$ $+(0.8670-(0.240306))^2+(-0.8891-(0.240306))^2$ Dividir a soma acima por 4.	1.611513

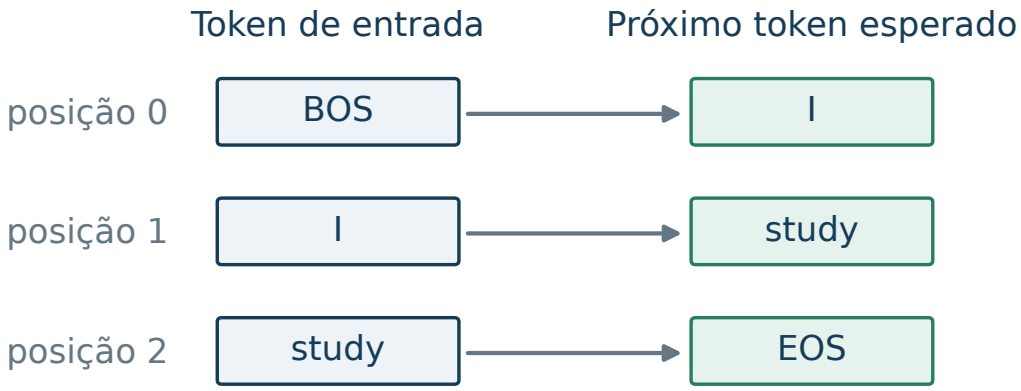
Normalização de G para obter a memória E - cada componente normalizada

Posição	Conta	Resultado
(1,1)	$\frac{2.0789-(0.210538)}{\sqrt{1.583757+0.00001}}$	1.4847
(1,2)	$\frac{0.4475-(0.210538)}{\sqrt{1.583757+0.00001}}$	0.1883
(1,3)	$\frac{-1.3768-(0.210538)}{\sqrt{1.583757+0.00001}}$	−1.2613
(1,4)	$\frac{-0.3075-(0.210538)}{\sqrt{1.583757+0.00001}}$	−0.4117
(2,1)	$\frac{-1.0334-(0.240306)}{\sqrt{1.611513+0.00001}}$	−1.0033
(2,2)	$\frac{2.0167-(0.240306)}{\sqrt{1.611513+0.00001}}$	1.3993
(2,3)	$\frac{0.8670-(0.240306)}{\sqrt{1.611513+0.00001}}$	0.4937
(2,4)	$\frac{-0.8891-(0.240306)}{\sqrt{1.611513+0.00001}}$	−0.8896

9. Preparando a entrada do decodificador

Para que serve esta etapa? Ensinar o decodificador a prever o próximo token a partir de um prefixo. O símbolo BOS permite a primeira previsão. Deslocar a saída em uma posição associa cada token de entrada ao token seguinte esperado.

Dimensões. Há 3 posições de previsão e 4 componentes por posição: $T \in \mathbb{R}^{3\times 4}$.



Leitura da imagem. O deslocamento de um token ensina o modelo a prever a palavra seguinte. BOS inicia a sequência; EOS indica o encerramento.

O decodificador usa um símbolo de início, ⟨BOS⟩, e um símbolo de encerramento, ⟨EOS⟩. A sequência esperada é:

$$[\text{I}, \text{study}, \langle\text{EOS}\rangle].$$

Durante o treinamento, a entrada é deslocada em uma posição:

Posição	Token fornecido	Próximo token esperado
0	⟨BOS⟩	I
1	I	study
2	study	⟨EOS⟩

Escolheremos:

Token	Embedding
⟨BOS⟩	$[1, 0, 0, 0]$
I	$[0, 1, 0, 0]$
study	$[0, 0, 1, 0]$

Aplicamos novamente $t_i = 2e_i + PE(i)$. Já conhecemos as posições 0 e 1; para a terceira posição:

$$PE(2) \approx [0.9093, -0.4161, 0.0200, 0.9998].$$

A matriz do decodificador é:

$$T \approx \begin{bmatrix} 2.0000 & 1.0000 & 0.0000 & 1.0000 \\ 0.8415 & 2.5403 & 0.0100 & 0.99995 \\ 0.9093 & -0.4161 & 2.0200 & 0.9998 \end{bmatrix}.$$

Na geração, essas linhas surgirão progressivamente. Mostramos todas juntas para acompanhar as contas; a máscara impedirá que uma posição use informações futuras.

Por que a entrada é deslocada? Para prever I, o modelo recebe BOS; para prever study, recebe o prefixo que termina em I. Assim, a palavra que se deseja prever aparece como alvo daquela posição, enquanto as entradas disponíveis representam o contexto anterior.

Cálculos posição a posição

Nas tabelas, (i, j) indica linha i e coluna j. Os resultados usam os valores completos; pequenas diferenças ao refazer as contas com os números impressos decorrem do arredondamento.

Escala dos embeddings de BOS, I e study

Posição	Conta	Resultado
(1,1)	$2.0 \times (1.0000)$	2.0000
(1,2)	$2.0 \times (0.0000)$	0.0000
(1,3)	$2.0 \times (0.0000)$	0.0000
(1,4)	$2.0 \times (0.0000)$	0.0000
(2,1)	$2.0 \times (0.0000)$	0.0000
(2,2)	$2.0 \times (1.0000)$	2.0000
(2,3)	$2.0 \times (0.0000)$	0.0000
(2,4)	$2.0 \times (0.0000)$	0.0000
(3,1)	$2.0 \times (0.0000)$	0.0000
(3,2)	$2.0 \times (0.0000)$	0.0000
(3,3)	$2.0 \times (1.0000)$	2.0000
(3,4)	$2.0 \times (0.0000)$	0.0000

Cada componente da codificação posicional

Posição	Conta	Resultado
(1,1)	$\sin\left(\frac{0}{1}\right)$	0.00000
(1,2)	$\cos\left(\frac{0}{1}\right)$	1.00000
(1,3)	$\sin\left(\frac{0}{100}\right)$	0.00000
(1,4)	$\cos\left(\frac{0}{100}\right)$	1.00000
(2,1)	$\sin\left(\frac{1}{1}\right)$	0.84147
(2,2)	$\cos\left(\frac{1}{1}\right)$	0.54030
(2,3)	$\sin\left(\frac{1}{100}\right)$	0.01000
(2,4)	$\cos\left(\frac{1}{100}\right)$	0.99995
(3,1)	$\sin\left(\frac{2}{1}\right)$	0.90930
(3,2)	$\cos\left(\frac{2}{1}\right)$	−0.41615
(3,3)	$\sin\left(\frac{2}{100}\right)$	0.02000
(3,4)	$\cos\left(\frac{2}{100}\right)$	0.99980

Embedding escalado + posição = T

Posição	Conta	Resultado
(1,1)	$2.00000 + (0.00000)$	2.00000
(1,2)	$0.00000 + (1.00000)$	1.00000
(1,3)	$0.00000 + (0.00000)$	0.00000
(1,4)	$0.00000 + (1.00000)$	1.00000
(2,1)	$0.00000 + (0.84147)$	0.84147
(2,2)	$2.00000 + (0.54030)$	2.54030

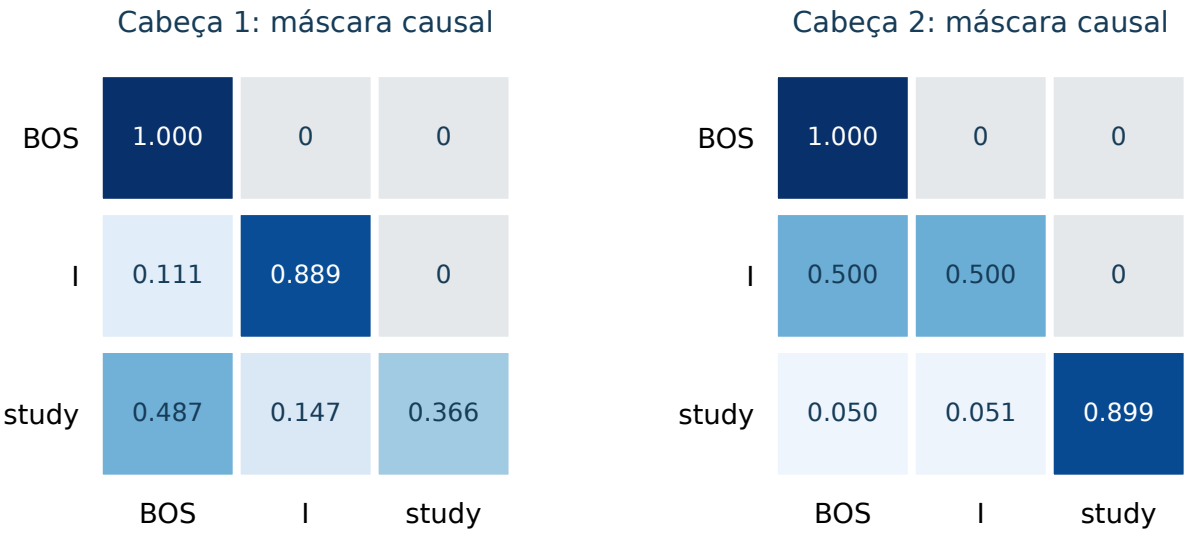
Continua na próxima página.

Posição	Conta (continuação)	Resultado
(2,3)	$0.00000 + (0.01000)$	0.01000
(2,4)	$0.00000 + (0.99995)$	0.99995
(3,1)	$0.00000 + (0.90930)$	0.90930
(3,2)	$0.00000 + (-0.41615)$	-0.41615
(3,3)	$2.00000 + (0.02000)$	2.02000
(3,4)	$0.00000 + (0.99980)$	0.99980

10. Calculando a autoatenção mascarada

Para que serve esta etapa? Construir uma representação de cada prefixo sem consultar as posições futuras. A máscara coloca $-\infty$ nos escores proibidos antes do softmax; depois dele, essas posições têm peso exatamente zero.

Dimensões. Cada cabeça produz uma matriz de pesos 3×3. A mistura dos valores produz 3×2 por cabeça; concatenar restaura 3×4.



Leitura da imagem. As células cinza são posições futuras. Elas recebem escore menos infinito antes do softmax e peso exatamente zero depois dele.

Usaremos as mesmas projeções J_1, J_2 e $W^O = I_4$. A diferença é a adição de uma máscara aos escores:

$$A_{\text{dec}} = \text{softmax}\left(\frac{QK^\top}{\sqrt{2}} + M\right).$$

Para três posições:

$$M = \begin{bmatrix} 0 & -\infty & -\infty \\ 0 & 0 & -\infty \\ 0 & 0 & 0 \end{bmatrix}.$$

Como $e^{-\infty} = 0$, as posições futuras recebem peso zero. Por exemplo, na primeira cabeça, a primeira linha fica:

$$\text{softmax}([3.5355, -\infty, -\infty]) = [1, 0, 0].$$

Os pesos das duas cabeças são:

$$A_{\text{dec},1} \approx \begin{bmatrix} 1 & 0 & 0 \\ 0.1113 & 0.8887 & 0 \\ 0.4868 & 0.1469 & 0.3663 \end{bmatrix}, \qquad A_{\text{dec},2} \approx \begin{bmatrix} 1 & 0 & 0 \\ 0.5000 & 0.5000 & 0 \\ 0.0502 & 0.0509 & 0.8989 \end{bmatrix}.$$

Multiplicando pelos respectivos valores e concatenando:

$$Z_{\text{dec}} \approx \begin{bmatrix} 2.0000 & 1.0000 & 0.0000 & 1.0000 \\ 0.9704 & 2.3689 & 0.0050 & 1.0000 \\ 1.4303 & 0.7076 & 1.8162 & 0.9998 \end{bmatrix}.$$

Agora aplicamos conexão residual e normalização:

$$U = \mathrm{LN}(T + Z_{\text{dec}}) \approx \begin{bmatrix} 1.4142 & 0.0000 & -1.4142 & 0.0000 \\ -0.2122 & 1.5539 & -1.2367 & -0.1050 \\ 0.1769 & -1.4485 & 1.3645 & -0.0929 \end{bmatrix}.$$

Cada linha incorpora informações do prefixo de saída permitido pela máscara. Ainda precisamos consultar a frase de entrada.

O que a máscara bloqueia? Na linha 1, apenas a coluna 1 é permitida. Na linha 2, as colunas 1 e 2 são permitidas. Na linha 3, as três colunas são permitidas. A diagonal é válida porque cada linha contém o token atual do prefixo e prevê o token seguinte.

Nas tabelas, calculamos também os escores que serão bloqueados para mostrar todas as células. Depois da máscara, as posições $(1, 2)$, $(1, 3)$ e $(2, 3)$ têm escore $-\infty$ e peso zero em ambas as cabeças.

Cálculos posição a posição

Nas tabelas, (i, j) indica linha i e coluna j. Os resultados usam os valores completos; pequenas diferenças ao refazer as contas com os números impressos decorrem do arredondamento.

Neste bloco, $Q_r = K_r = V_r = TJ_r$. Calculamos cada projeção uma vez porque os três conjuntos de pesos são iguais no exemplo.

Projeções do decodificador - cabeça 1

Posição	Conta	Resultado
(1,1)	$(2.0000) \times 1 + (1.0000) \times 0$ $+(0.0000) \times 0 + (1.0000) \times 0$	2.0000
(1,2)	$(2.0000) \times 0 + (1.0000) \times 1$ $+(0.0000) \times 0 + (1.0000) \times 0$	1.0000
(2,1)	$(0.8415) \times 1 + (2.5403) \times 0$ $+(0.0100) \times 0 + (1.0000) \times 0$	0.8415
(2,2)	$(0.8415) \times 0 + (2.5403) \times 1$ $+(0.0100) \times 0 + (1.0000) \times 0$	2.5403
(3,1)	$(0.9093) \times 1 + (-0.4161) \times 0$ $+(2.0200) \times 0 + (0.9998) \times 0$	0.9093
(3,2)	$(0.9093) \times 0 + (-0.4161) \times 1$ $+(2.0200) \times 0 + (0.9998) \times 0$	−0.4161

Projeções do decodificador - cabeça 2

Posição	Conta	Resultado
(1,1)	$(2.0000) \times 0 + (1.0000) \times 0 + (0.0000) \times 1 + (1.0000) \times 0$	0.0000
(1,2)	$(2.0000) \times 0 + (1.0000) \times 0 + (0.0000) \times 0 + (1.0000) \times 1$	1.0000
(2,1)	$(0.8415) \times 0 + (2.5403) \times 0 + (0.0100) \times 1 + (1.0000) \times 0$	0.0100
(2,2)	$(0.8415) \times 0 + (2.5403) \times 0 + (0.0100) \times 0 + (1.0000) \times 1$	1.0000
(3,1)	$(0.9093) \times 0 + (-0.4161) \times 0 + (2.0200) \times 1 + (0.9998) \times 0$	2.0200
(3,2)	$(0.9093) \times 0 + (-0.4161) \times 0 + (2.0200) \times 0 + (0.9998) \times 1$	0.9998

Escores da cabeça 1: $(QK^\top)/\sqrt{2}$

Posição	Conta	Resultado
(1,1)	$\frac{(2.0000)(2.0000) + (1.0000)(1.0000)}{\sqrt{2}}$	3.5355
(1,2)	$\frac{(2.0000)(0.8415) + (1.0000)(2.5403)}{\sqrt{2}}$ Futuro: aplicar máscara depois.	2.9863
(1,3)	$\frac{(2.0000)(0.9093) + (1.0000)(-0.4161)}{\sqrt{2}}$ Futuro: aplicar máscara depois.	0.9917
(2,1)	$\frac{(0.8415)(2.0000) + (2.5403)(1.0000)}{\sqrt{2}}$	2.9863
(2,2)	$\frac{(0.8415)(0.8415) + (2.5403)(2.5403)}{\sqrt{2}}$	5.0637
(2,3)	$\frac{(0.8415)(0.9093) + (2.5403)(-0.4161)}{\sqrt{2}}$ Futuro: aplicar máscara depois.	−0.2065
(3,1)	$\frac{(0.9093)(2.0000) + (-0.4161)(1.0000)}{\sqrt{2}}$	0.9917
(3,2)	$\frac{(0.9093)(0.8415) + (-0.4161)(2.5403)}{\sqrt{2}}$	−0.2065
(3,3)	$\frac{(0.9093)(0.9093) + (-0.4161)(-0.4161)}{\sqrt{2}}$	0.7071

Aplicação da máscara. Substituir os escores $(1,2)$, $(1,3)$ e $(2,3)$ por $-\infty$. Nas contas do softmax abaixo, $e^{-\infty} = 0$.

Softmax causal - cabeça 1 - denominador de cada linha

Posição	Conta	N_i
linha 1	$e^{3.5355} + e^{-\infty} + e^{-\infty}$	34.3133
linha 2	$e^{2.9863} + e^{5.0637} + e^{-\infty}$	177.9929
linha 3	$e^{0.9917} + e^{-0.2065} + e^{0.7071}$	5.5373

Softmax causal - cabeça 1 - cada peso

Posição	Conta	Resultado
(1,1)	$\frac{e^{3.5355}}{34.3133}$	1.0000
(1,2)	$\frac{e^{-\infty}}{34.3133} = 0$	0.0000
(1,3)	$\frac{e^{-\infty}}{34.3133} = 0$	0.0000
(2,1)	$\frac{e^{2.9863}}{177.9929}$	0.1113
(2,2)	$\frac{e^{5.0637}}{177.9929}$	0.8887
(2,3)	$\frac{e^{-\infty}}{177.9929} = 0$	0.0000
(3,1)	$\frac{e^{0.9917}}{5.5373}$	0.4868
(3,2)	$\frac{e^{-0.2065}}{5.5373}$	0.1469
(3,3)	$\frac{e^{0.7071}}{5.5373}$	0.3663

Escores da cabeça 2: $(QK^\top)/\sqrt{2}$

Posição	Conta	Resultado
(1,1)	$\frac{(0.0000)(0.0000)+(1.0000)(1.0000)}{\sqrt{2}}$	0.7071
(1,2)	$\frac{(0.0000)(0.0100)+(1.0000)(1.0000)}{\sqrt{2}}$ Futuro: aplicar máscara depois.	0.7071
(1,3)	$\frac{(0.0000)(2.0200)+(1.0000)(0.9998)}{\sqrt{2}}$ Futuro: aplicar máscara depois.	0.7070
(2,1)	$\frac{(0.0100)(0.0000)+(1.0000)(1.0000)}{\sqrt{2}}$	0.7071
(2,2)	$\frac{(0.0100)(0.0100)+(1.0000)(1.0000)}{\sqrt{2}}$	0.7071
(2,3)	$\frac{(0.0100)(2.0200)+(1.0000)(0.9998)}{\sqrt{2}}$ Futuro: aplicar máscara depois.	0.7212
(3,1)	$\frac{(2.0200)(0.0000)+(0.9998)(1.0000)}{\sqrt{2}}$	0.7070
(3,2)	$\frac{(2.0200)(0.0100)+(0.9998)(1.0000)}{\sqrt{2}}$	0.7212
(3,3)	$\frac{(2.0200)(2.0200)+(0.9998)(0.9998)}{\sqrt{2}}$	3.5921

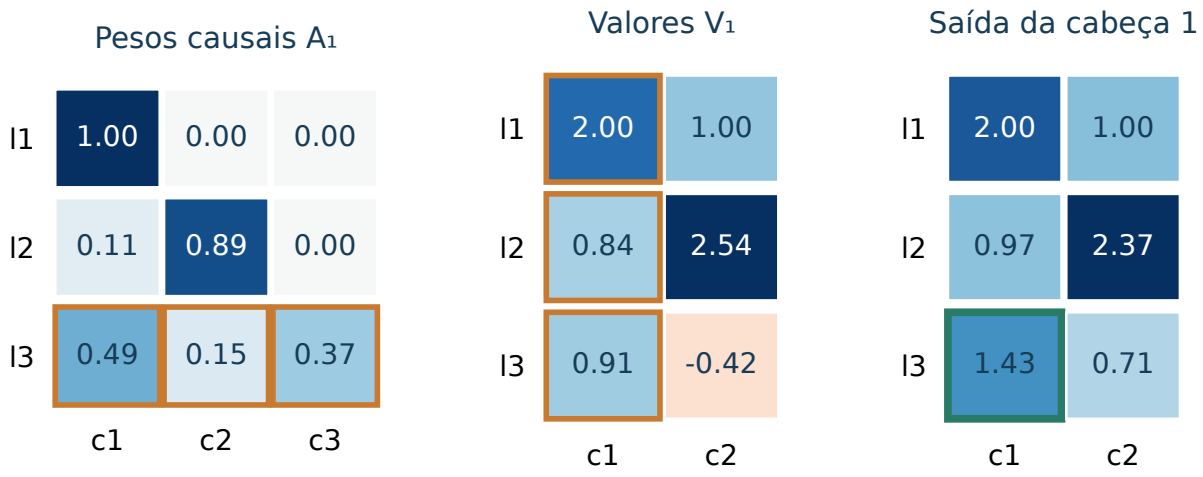
Aplicação da máscara. Substituir os escores $(1,2)$, $(1,3)$ e $(2,3)$ por $-\infty$. Nas contas do softmax abaixo, $e^{-\infty}=0$.

Softmax causal - cabeça 2 - denominador de cada linha

Posição	Conta	N_i
linha 1	$e^{0.7071}+e^{-\infty}+e^{-\infty}$	2.0281
linha 2	$e^{0.7071}+e^{0.7071}+e^{-\infty}$	4.0562
linha 3	$e^{0.7070}+e^{0.7212}+e^{3.5921}$	40.3950

Softmax causal - cabeça 2 - cada peso

Posição	Conta	Resultado
(1,1)	$\frac{e^{0.7071}}{2.0281}$	1.0000
(1,2)	$\frac{e^{-\infty}}{2.0281} = 0$	0.0000
(1,3)	$\frac{e^{-\infty}}{2.0281} = 0$	0.0000
(2,1)	$\frac{e^{0.7071}}{4.0562}$	0.5000
(2,2)	$\frac{e^{0.7071}}{4.0562}$	0.5000
(2,3)	$\frac{e^{-\infty}}{4.0562} = 0$	0.0000
(3,1)	$\frac{e^{0.7070}}{40.3950}$	0.0502
(3,2)	$\frac{e^{0.7212}}{40.3950}$	0.0509
(3,3)	$\frac{e^{3.5921}}{40.3950}$	0.8989



Leitura da imagem. A linha 3 pode combinar BOS, I e study. A linha 1 usa apenas BOS. As contas da tabela abaixo mostram cada componente dessa multiplicação.

Valores ponderados - cabeça 1

Posição	Conta	Resultado
(1,1)	$(1.0000)(2.0000) + (0.0000)(0.8415) + (0.0000)(0.9093)$	2.0000
(1,2)	$(1.0000)(1.0000) + (0.0000)(2.5403) + (0.0000)(-0.4161)$	1.0000
(2,1)	$(0.1113)(2.0000) + (0.8887)(0.8415) + (0.0000)(0.9093)$	0.9704
(2,2)	$(0.1113)(1.0000) + (0.8887)(2.5403) + (0.0000)(-0.4161)$	2.3689
(3,1)	$(0.4868)(2.0000) + (0.1469)(0.8415) + (0.3663)(0.9093)$	1.4303
(3,2)	$(0.4868)(1.0000) + (0.1469)(2.5403) + (0.3663)(-0.4161)$	0.7076

Valores ponderados - cabeça 2

Posição	Conta	Resultado
(1,1)	$(1.0000)(0.0000) + (0.0000)(0.0100) + (0.0000)(2.0200)$	0.0000
(1,2)	$(1.0000)(1.0000) + (0.0000)(1.0000) + (0.0000)(0.9998)$	1.0000
(2,1)	$(0.5000)(0.0000) + (0.5000)(0.0100) + (0.0000)(2.0200)$	0.0050
(2,2)	$(0.5000)(1.0000) + (0.5000)(1.0000) + (0.0000)(0.9998)$	1.0000
(3,1)	$(0.0502)(0.0000) + (0.0509)(0.0100) + (0.8989)(2.0200)$	1.8162
(3,2)	$(0.0502)(1.0000) + (0.0509)(1.0000) + (0.8989)(0.9998)$	0.9998

Concatenação para obter Z_{dec}

Cada célula é copiada da cabeça indicada; concatenar reorganiza as colunas.

Posição	Conta	Resultado
(1,1)	$Z^{(1)}_{1,1}$	2.0000
(1,2)	$Z^{(1)}_{1,2}$	1.0000
(1,3)	$Z^{(2)}_{1,1}$	0.0000

Continua na próxima página.

Posição	Conta (continuação)	Resultado
(1,4)	$Z_{1,2}^{(2)}$	1.0000
(2,1)	$Z_{2,1}^{(1)}$	0.9704
(2,2)	$Z_{2,2}^{(1)}$	2.3689
(2,3)	$Z_{2,1}^{(2)}$	0.0050
(2,4)	$Z_{2,2}^{(2)}$	1.0000
(3,1)	$Z_{3,1}^{(1)}$	1.4303
(3,2)	$Z_{3,2}^{(1)}$	0.7076
(3,3)	$Z_{3,1}^{(2)}$	1.8162
(3,4)	$Z_{3,2}^{(2)}$	0.9998

Conexão residual $R_{\text{dec}} = T + Z_{\text{dec}}$

Posição	Conta	Resultado
(1,1)	$2.0000 + (2.0000)$	4.0000
(1,2)	$1.0000 + (1.0000)$	2.0000
(1,3)	$0.0000 + (0.0000)$	0.0000
(1,4)	$1.0000 + (1.0000)$	2.0000
(2,1)	$0.8415 + (0.9704)$	1.8119
(2,2)	$2.5403 + (2.3689)$	4.9092
(2,3)	$0.0100 + (0.0050)$	0.0150
(2,4)	$1.0000 + (1.0000)$	1.9999
(3,1)	$0.9093 + (1.4303)$	2.3396
(3,2)	$-0.4161 + (0.7076)$	0.2914
(3,3)	$2.0200 + (1.8162)$	3.8362
(3,4)	$0.9998 + (0.9998)$	1.9996

Normalização para obter U - média e variância por token

Posição	Conta	Resultado
média 1	$\frac{(4.0000) + (2.0000) + (0.0000) + (2.0000)}{4}$	2.000000

Continua na próxima página.

Posição	Conta (continuação)	Resultado
var. 1	$(4.0000-(2.000000))^2+(2.0000-(2.000000))^2$ $+(0.0000-(2.000000))^2+(2.0000-(2.000000))^2$ Dividir a soma acima por 4.	2.000000
média 2	$\frac{(1.8119)+(4.9092)+(0.0150)+(1.9999)}{4}$	2.183994
var. 2	$(1.8119-(2.183994))^2+(4.9092-(2.183994))^2$ $+(0.0150-(2.183994))^2+(1.9999-(2.183994))^2$ Dividir a soma acima por 4.	3.075848
média 3	$\frac{(2.3396)+(0.2914)+(3.8362)+(1.9996)}{4}$	2.116733
var. 3	$(2.3396-(2.116733))^2+(0.2914-(2.116733))^2$ $+(3.8362-(2.116733))^2+(1.9996-(2.116733))^2$ Dividir a soma acima por 4.	1.587945

Normalização para obter U - cada componente normalizada

Posição	Conta	Resultado
(1,1)	$\frac{4.0000-(2.000000)}{\sqrt{2.000000+0.00001}}$	1.4142
(1,2)	$\frac{2.0000-(2.000000)}{\sqrt{2.000000+0.00001}}$	0.0000
(1,3)	$\frac{0.0000-(2.000000)}{\sqrt{2.000000+0.00001}}$	−1.4142
(1,4)	$\frac{2.0000-(2.000000)}{\sqrt{2.000000+0.00001}}$	0.0000
(2,1)	$\frac{1.8119-(2.183994)}{\sqrt{3.075848+0.00001}}$	−0.2122
(2,2)	$\frac{4.9092-(2.183994)}{\sqrt{3.075848+0.00001}}$	1.5539
(2,3)	$\frac{0.0150-(2.183994)}{\sqrt{3.075848+0.00001}}$	−1.2367
(2,4)	$\frac{1.9999-(2.183994)}{\sqrt{3.075848+0.00001}}$	−0.1050
(3,1)	$\frac{2.3396-(2.116733)}{\sqrt{1.587945+0.00001}}$	0.1769
(3,2)	$\frac{0.2914-(2.116733)}{\sqrt{1.587945+0.00001}}$	−1.4485

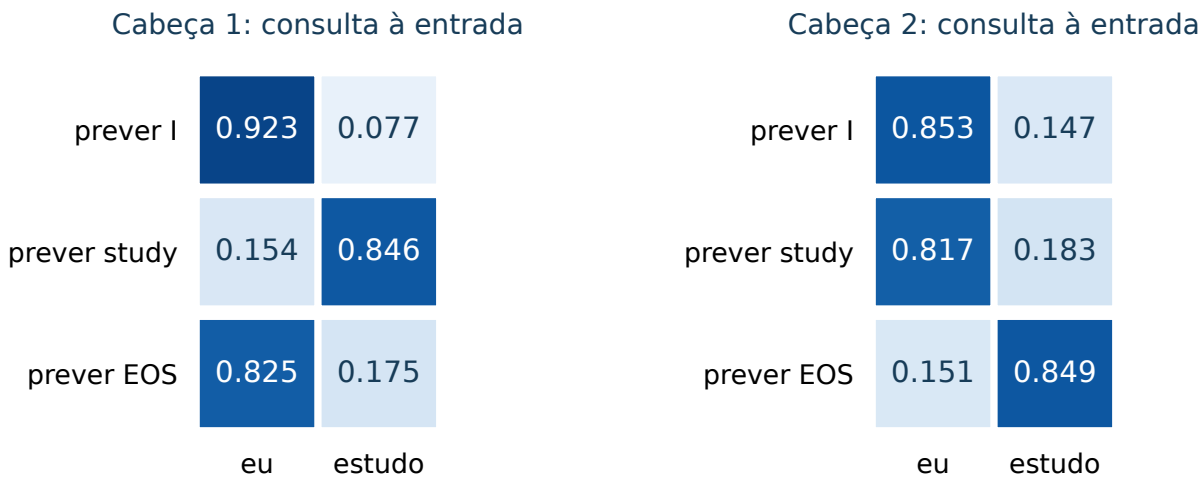
Continua na próxima página.

Posição	Conta (continuação)	Resultado
(3,3)	$\frac{3.8362 - (2.116733)}{\sqrt{1.587945 + 0.00001}}$	1.3645
(3,4)	$\frac{1.9996 - (2.116733)}{\sqrt{1.587945 + 0.00001}}$	-0.0929

11. Fazendo a atenção entre decodificador e codificador

Para que serve esta etapa? Permitir que cada previsão consulte a frase de entrada. As consultas vêm do decodificador, enquanto as chaves e os valores vêm da memória E. Os pesos indicam como combinar os valores do codificador para cada posição de saída.

Dimensões. $(3 \times 2)(2 \times 2) \to 3 \times 2$ escores: três consultas e duas posições de entrada. A atenção cruzada não exige comprimentos iguais nas duas sequências.



Leitura da imagem. As linhas correspondem às três previsões do decodificador; as colunas, às duas posições da frase de entrada. As duas cabeças podem distribuir pesos de modo diferente.

Esta etapa é chamada de atenção cruzada, ou atenção codificador-decodificador. Agora:

$$Q_r = UJ_r, \qquad K_r = EJ_r, \qquad V_r = EJ_r.$$

As consultas vêm do decodificador; as chaves e os valores vêm da saída do codificador. Para cada cabeça:

$$C_r = \text{softmax}\left(\frac{(UJ_r)(EJ_r)^\top}{\sqrt{2}}\right)(EJ_r).$$

Considere a primeira consulta da primeira cabeça:

$$q = [1.4142, 0].$$

As chaves são retiradas das duas linhas de E:

$$k_{\text{eu}} = [1.4847, 0.1883],$$
$$k_{\text{estudo}} = [-1.0033, 1.3993].$$

Os escores são:

$$\frac{q \cdot k_{\text{eu}}}{\sqrt{2}} \approx 1.4847, \qquad \frac{q \cdot k_{\text{estudo}}}{\sqrt{2}} \approx -1.0033.$$

Depois do softmax, obtemos $[0.9233, 0.0767]$. Nessa consulta e nessa cabeça, a combinação utiliza aproximadamente 92,33% do valor da posição de “eu” e 7,67% do valor da posição de “estudo”.

Para todas as consultas:

$$A_{\text{cross},1} \approx \begin{bmatrix} 0.9233 & 0.0767 \\ 0.1540 & 0.8460 \\ 0.8251 & 0.1749 \end{bmatrix}, \qquad A_{\text{cross},2} \approx \begin{bmatrix} 0.8526 & 0.1474 \\ 0.8175 & 0.1825 \\ 0.1513 & 0.8487 \end{bmatrix}.$$

Cada linha soma 1, antes dos arredondamentos. As duas colunas correspondem às duas posições da entrada.

Multiplicando pelos valores e reunindo as cabeças:

$$C \approx \begin{bmatrix} 1.2938 & 0.2812 & -1.0026 & -0.4821 \\ -0.6203 & 1.2129 & -0.9409 & -0.4989 \\ 1.0496 & 0.4001 & 0.2282 & -0.8173 \end{bmatrix}.$$

Essa matriz contém a informação consultada no codificador para cada posição do decodificador.

O que mudou em relação à autoatenção? A origem das matrizes mudou: Q é calculada a partir de U, mas K e V são calculadas a partir de E. Por exemplo, a linha usada para prever study pode consultar as duas posições da frase eu estudo.

Como ler 84.60%. Na cabeça 1, esse é o peso usado para multiplicar o vetor de valor da segunda posição do codificador na consulta que prevê study. A outra cabeça pode distribuir seus pesos de outra maneira.

Cálculos posição a posição

Nas tabelas, (i, j) indica linha i e coluna j. Os resultados usam os valores completos; pequenas diferenças ao refazer as contas com os números impressos decorrem do arredondamento.

As consultas são $Q_r = UJ_r$. As chaves e os valores são $K_r = V_r = EJ_r$ com os seletores escolhidos. A origem de Q é diferente da origem de K e V.

Consultas do decodificador: UJ_r - cabeça 1

Posição	Conta	Resultado
(1,1)	$(1.4142) \times 1 + (0.0000) \times 0$ $+(-1.4142) \times 0 + (0.0000) \times 0$	1.4142
(1,2)	$(1.4142) \times 0 + (0.0000) \times 1$ $+(-1.4142) \times 0 + (0.0000) \times 0$	0.0000
(2,1)	$(-0.2122) \times 1 + (1.5539) \times 0$ $+(-1.2367) \times 0 + (-0.1050) \times 0$	−0.2122
(2,2)	$(-0.2122) \times 0 + (1.5539) \times 1$ $+(-1.2367) \times 0 + (-0.1050) \times 0$	1.5539
(3,1)	$(0.1769) \times 1 + (-1.4485) \times 0$ $+(1.3645) \times 0 + (-0.0929) \times 0$	0.1769

Continua na próxima página.

Posição	Conta (continuação)	Resultado
(3,2)	$(0.1769) \times 0 + (-1.4485) \times 1$ $+(1.3645) \times 0 + (-0.0929) \times 0$	-1.4485

Consultas do decodificador: UJ_r - cabeça 2

Posição	Conta	Resultado
(1,1)	$(1.4142) \times 0 + (0.0000) \times 0$ $+(-1.4142) \times 1 + (0.0000) \times 0$	-1.4142
(1,2)	$(1.4142) \times 0 + (0.0000) \times 0$ $+(-1.4142) \times 0 + (0.0000) \times 1$	0.0000
(2,1)	$(-0.2122) \times 0 + (1.5539) \times 0$ $+(-1.2367) \times 1 + (-0.1050) \times 0$	-1.2367
(2,2)	$(-0.2122) \times 0 + (1.5539) \times 0$ $+(-1.2367) \times 0 + (-0.1050) \times 1$	-0.1050
(3,1)	$(0.1769) \times 0 + (-1.4485) \times 0$ $+(1.3645) \times 1 + (-0.0929) \times 0$	1.3645
(3,2)	$(0.1769) \times 0 + (-1.4485) \times 0$ $+(1.3645) \times 0 + (-0.0929) \times 1$	-0.0929

Chaves e valores da memória: EJ_r - cabeça 1

Posição	Conta	Resultado
(1,1)	$(1.4847) \times 1 + (0.1883) \times 0$ $+(-1.2613) \times 0 + (-0.4117) \times 0$	1.4847
(1,2)	$(1.4847) \times 0 + (0.1883) \times 1$ $+(-1.2613) \times 0 + (-0.4117) \times 0$	0.1883
(2,1)	$(-1.0033) \times 1 + (1.3993) \times 0$ $+(0.4937) \times 0 + (-0.8896) \times 0$	-1.0033
(2,2)	$(-1.0033) \times 0 + (1.3993) \times 1$ $+(0.4937) \times 0 + (-0.8896) \times 0$	1.3993

Chaves e valores da memória: EJ_r - cabeça 2

Posição	Conta	Resultado
(1,1)	$(1.4847) \times 0 + (0.1883) \times 0$ $+(-1.2613) \times 1 + (-0.4117) \times 0$	-1.2613

Continua na próxima página.

Posição	Conta (continuação)	Resultado
(1,2)	$(1.4847) \times 0 + (0.1883) \times 0 + (-1.2613) \times 0 + (-0.4117) \times 1$	-0.4117
(2,1)	$(-1.0033) \times 0 + (1.3993) \times 0 + (0.4937) \times 1 + (-0.8896) \times 0$	0.4937
(2,2)	$(-1.0033) \times 0 + (1.3993) \times 0 + (0.4937) \times 0 + (-0.8896) \times 1$	-0.8896

Escores cruzados - cabeça 1

Posição	Conta	Resultado
(1,1)	$\frac{(1.4142)(1.4847) + (0.0000)(0.1883)}{\sqrt{2}}$	1.4847
(1,2)	$\frac{(1.4142)(-1.0033) + (0.0000)(1.3993)}{\sqrt{2}}$	-1.0033
(2,1)	$\frac{(-0.2122)(1.4847) + (1.5539)(0.1883)}{\sqrt{2}}$	-0.0158
(2,2)	$\frac{(-0.2122)(-1.0033) + (1.5539)(1.3993)}{\sqrt{2}}$	1.6880
(3,1)	$\frac{(0.1769)(1.4847) + (-1.4485)(0.1883)}{\sqrt{2}}$	-0.0072
(3,2)	$\frac{(0.1769)(-1.0033) + (-1.4485)(1.3993)}{\sqrt{2}}$	-1.5587

Softmax cruzado - cabeça 1 - denominador de cada linha

Posição	Conta	N_i
linha 1	$e^{1.4847} + e^{-1.0033}$	4.7801
linha 2	$e^{-0.0158} + e^{1.6880}$	6.3931
linha 3	$e^{-0.0072} + e^{-1.5587}$	1.2033

Softmax cruzado - cabeça 1 - cada peso

Posição	Conta	Resultado
(1,1)	$\frac{e^{1.4847}}{4.7801}$	0.9233
(1,2)	$\frac{e^{-1.0033}}{4.7801}$	0.0767
(2,1)	$\frac{e^{-0.0158}}{6.3931}$	0.1540
(2,2)	$\frac{e^{1.6880}}{6.3931}$	0.8460
(3,1)	$\frac{e^{-0.0072}}{1.2033}$	0.8251
(3,2)	$\frac{e^{-1.5587}}{1.2033}$	0.1749

Escores cruzados - cabeça 2

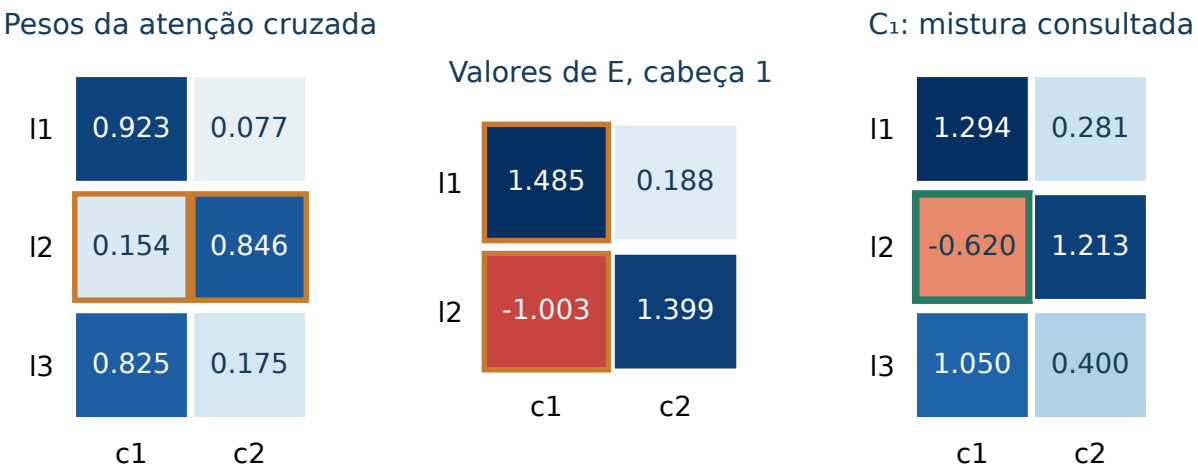
Posição	Conta	Resultado
(1,1)	$\frac{(-1.4142)(-1.2613)+(0.0000)(-0.4117)}{\sqrt{2}}$	1.2613
(1,2)	$\frac{(-1.4142)(0.4937)+(0.0000)(-0.8896)}{\sqrt{2}}$	−0.4937
(2,1)	$\frac{(-1.2367)(-1.2613)+(-0.1050)(-0.4117)}{\sqrt{2}}$	1.1335
(2,2)	$\frac{(-1.2367)(0.4937)+(-0.1050)(-0.8896)}{\sqrt{2}}$	−0.3657
(3,1)	$\frac{(1.3645)(-1.2613)+(-0.0929)(-0.4117)}{\sqrt{2}}$	−1.1899
(3,2)	$\frac{(1.3645)(0.4937)+(-0.0929)(-0.8896)}{\sqrt{2}}$	0.5348

Softmax cruzado - cabeça 2 - denominador de cada linha

Posição	Conta	N_i
linha 1	$e^{1.2613} + e^{-0.4937}$	4.1403
linha 2	$e^{1.1335} + e^{-0.3657}$	3.8004
linha 3	$e^{-1.1899} + e^{0.5348}$	2.0113

Softmax cruzado - cabeça 2 - cada peso

Posição	Conta	Resultado
(1,1)	$\frac{e^{1.2613}}{4.1403}$	0.8526
(1,2)	$\frac{e^{-0.4937}}{4.1403}$	0.1474
(2,1)	$\frac{e^{1.1335}}{3.8004}$	0.8175
(2,2)	$\frac{e^{-0.3657}}{3.8004}$	0.1825
(3,1)	$\frac{e^{-1.1899}}{2.0113}$	0.1513
(3,2)	$\frac{e^{0.5348}}{2.0113}$	0.8487



Leitura da imagem. Na linha que prevê study, a cabeça 1 usa 15.40% do primeiro valor do codificador e 84.60% do segundo.

Valores consultados - cabeça 1

Posição	Conta	Resultado
(1,1)	$(0.9233)(1.4847) + (0.0767)(-1.0033)$	1.2938
(1,2)	$(0.9233)(0.1883) + (0.0767)(1.3993)$	0.2812
(2,1)	$(0.1540)(1.4847) + (0.8460)(-1.0033)$	−0.6203
(2,2)	$(0.1540)(0.1883) + (0.8460)(1.3993)$	1.2129
(3,1)	$(0.8251)(1.4847) + (0.1749)(-1.0033)$	1.0496
(3,2)	$(0.8251)(0.1883) + (0.1749)(1.3993)$	0.4001

Valores consultados - cabeça 2

Posição	Conta	Resultado
(1,1)	$(0.8526)(-1.2613) + (0.1474)(0.4937)$	−1.0026
(1,2)	$(0.8526)(-0.4117) + (0.1474)(-0.8896)$	−0.4821
(2,1)	$(0.8175)(-1.2613) + (0.1825)(0.4937)$	−0.9409
(2,2)	$(0.8175)(-0.4117) + (0.1825)(-0.8896)$	−0.4989
(3,1)	$(0.1513)(-1.2613) + (0.8487)(0.4937)$	0.2282
(3,2)	$(0.1513)(-0.4117) + (0.8487)(-0.8896)$	−0.8173

Concatenação para obter C

Cada célula é copiada da cabeça indicada; concatenar reorganiza as colunas.

Posição	Conta	Resultado
(1,1)	$Z^{(1)}_{1,1}$	1.2938
(1,2)	$Z^{(1)}_{1,2}$	0.2812
(1,3)	$Z^{(2)}_{1,1}$	−1.0026
(1,4)	$Z^{(2)}_{1,2}$	−0.4821
(2,1)	$Z^{(1)}_{2,1}$	−0.6203
(2,2)	$Z^{(1)}_{2,2}$	1.2129
(2,3)	$Z^{(2)}_{2,1}$	−0.9409
(2,4)	$Z^{(2)}_{2,2}$	−0.4989
(3,1)	$Z^{(1)}_{3,1}$	1.0496
(3,2)	$Z^{(1)}_{3,2}$	0.4001

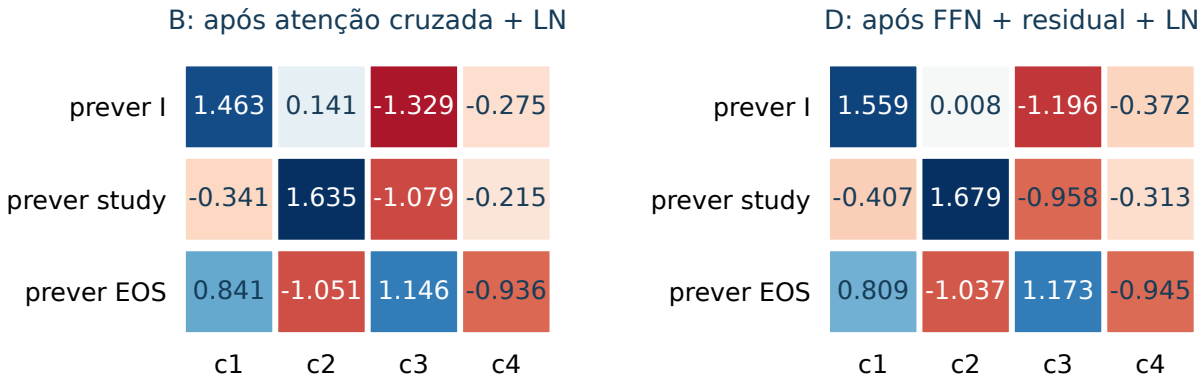
Continua na próxima página.

Posição	Conta (continuação)	Resultado
(3,3)	$Z^{(2)}_{3,1}$	0.2282
(3,4)	$Z^{(2)}_{3,2}$	-0.8173

12. Concluindo o bloco do decodificador

Para que serve esta etapa? Integrar a informação consultada na entrada à representação do prefixo e aplicar uma transformação não linear antes da previsão. Cada linha passa por soma residual, normalização e FFN sem trocar sua posição.

Dimensões. As matrizes permanecem 3×4 ao longo desta etapa.



Leitura da imagem. A FFN e a normalização transformam as componentes de cada linha, mantendo as três posições e as quatro componentes.

Primeiro, somamos a saída da atenção cruzada à entrada dessa subcamada:

$$B = \mathrm{LN}(U + C).$$

Obtemos:

$$B \approx \begin{bmatrix} 1.4627 & 0.1409 & -1.3286 & -0.2749 \\ -0.3407 & 1.6350 & -1.0791 & -0.2152 \\ 0.8411 & -1.0508 & 1.1456 & -0.9359 \end{bmatrix}.$$

Em seguida, aplicamos a mesma FFN definida anteriormente:

$$\mathrm{FFN}(B) = 0.5\,\mathrm{ReLU}(B).$$

Fazemos a última soma residual e normalização:

$$D = \mathrm{LN}\big(B + 0.5\,\mathrm{ReLU}(B)\big).$$

O resultado final do decodificador é:

$$D \approx \begin{bmatrix} 1.5593 & 0.0085 & -1.1960 & -0.3718 \\ -0.4070 & 1.6786 & -0.9583 & -0.3133 \\ 0.8088 & -1.0370 & 1.1735 & -0.9453 \end{bmatrix}.$$

Cada linha é usada para prever o próximo token:

Linha de D	Previsão correspondente
0	Primeiro token, após ⟨BOS⟩.
1	Próximo token, após I.
2	Próximo token, após I study.

Que informação chega à projeção final? Cada linha de D reúne informação do prefixo permitido pela máscara, informação consultada na entrada e as transformações realizadas pelas subcamadas. A posição da linha determina qual próximo token será previsto.

Cálculos posição a posição

Nas tabelas, (i, j) indica linha i e coluna j. Os resultados usam os valores completos; pequenas diferenças ao refazer as contas com os números impressos decorrem do arredondamento.

Soma residual $R_{\text{cross}} = U + C$

Posição	Conta	Resultado
(1,1)	$1.4142 + (1.2938)$	2.7080
(1,2)	$0.0000 + (0.2812)$	0.2812
(1,3)	$-1.4142 + (-1.0026)$	-2.4168
(1,4)	$0.0000 + (-0.4821)$	-0.4821
(2,1)	$-0.2122 + (-0.6203)$	-0.8325
(2,2)	$1.5539 + (1.2129)$	2.7667
(2,3)	$-1.2367 + (-0.9409)$	-2.1777
(2,4)	$-0.1050 + (-0.4989)$	-0.6039
(3,1)	$0.1769 + (1.0496)$	1.2265
(3,2)	$-1.4485 + (0.4001)$	-1.0484
(3,3)	$1.3645 + (0.2282)$	1.5927
(3,4)	$-0.0929 + (-0.8173)$	-0.9103

Normalização para obter B - média e variância por token

Posição	Conta	Resultado
média 1	$\dfrac{(2.7080) + (0.2812) + (-2.4168) + (-0.4821)}{4}$	0.022577
var. 1	$(2.7080 - (0.022577))^2 + (0.2812 - (0.022577))^2$ $+(-2.4168 - (0.022577))^2 + (-0.4821 - (0.022577))^2$ Dividir a soma acima por 4.	3.370918
média 2	$\dfrac{(-0.8325) + (2.7667) + (-2.1777) + (-0.6039)}{4}$	-0.211817

Continua na próxima página.

Posição	Conta (continuação)	Resultado
var. 2	$(-0.8325-(-0.211817))^2+(2.7667-(-0.211817))^2$ $+(-2.1777-(-0.211817))^2+(-0.6039-(-0.211817))^2$ Dividir a soma acima por 4.	3.318798
média 3	$\frac{(1.2265)+(-1.0484)+(1.5927)+(-0.9103)}{4}$	0.215129
var. 3	$(1.2265-(0.215129))^2+(-1.0484-(0.215129))^2$ $+(1.5927-(0.215129))^2+(-0.9103-(0.215129))^2$ Dividir a soma acima por 4.	1.445918

Normalização para obter B - cada componente normalizada

Posição	Conta	Resultado
(1,1)	$\frac{2.7080-(0.022577)}{\sqrt{3.370918+0.00001}}$	1.4627
(1,2)	$\frac{0.2812-(0.022577)}{\sqrt{3.370918+0.00001}}$	0.1409
(1,3)	$\frac{-2.4168-(0.022577)}{\sqrt{3.370918+0.00001}}$	−1.3286
(1,4)	$\frac{-0.4821-(0.022577)}{\sqrt{3.370918+0.00001}}$	−0.2749
(2,1)	$\frac{-0.8325-(-0.211817)}{\sqrt{3.318798+0.00001}}$	−0.3407
(2,2)	$\frac{2.7667-(-0.211817)}{\sqrt{3.318798+0.00001}}$	1.6350
(2,3)	$\frac{-2.1777-(-0.211817)}{\sqrt{3.318798+0.00001}}$	−1.0791
(2,4)	$\frac{-0.6039-(-0.211817)}{\sqrt{3.318798+0.00001}}$	−0.2152
(3,1)	$\frac{1.2265-(0.215129)}{\sqrt{1.445918+0.00001}}$	0.8411
(3,2)	$\frac{-1.0484-(0.215129)}{\sqrt{1.445918+0.00001}}$	−1.0508
(3,3)	$\frac{1.5927-(0.215129)}{\sqrt{1.445918+0.00001}}$	1.1456
(3,4)	$\frac{-0.9103-(0.215129)}{\sqrt{1.445918+0.00001}}$	−0.9359

Cada componente de $F_{\text{dec}} = 0.5\,\text{ReLU}(B)$

Posição	Conta	Resultado
(1,1)	$0.5 \times \max(0, 1.4627)$	0.7313
(1,2)	$0.5 \times \max(0, 0.1409)$	0.0704
(1,3)	$0.5 \times \max(0, -1.3286)$	0.0000
(1,4)	$0.5 \times \max(0, -0.2749)$	0.0000
(2,1)	$0.5 \times \max(0, -0.3407)$	0.0000
(2,2)	$0.5 \times \max(0, 1.6350)$	0.8175
(2,3)	$0.5 \times \max(0, -1.0791)$	0.0000
(2,4)	$0.5 \times \max(0, -0.2152)$	0.0000
(3,1)	$0.5 \times \max(0, 0.8411)$	0.4205
(3,2)	$0.5 \times \max(0, -1.0508)$	0.0000
(3,3)	$0.5 \times \max(0, 1.1456)$	0.5728
(3,4)	$0.5 \times \max(0, -0.9359)$	0.0000

Soma residual $G_{\text{dec}} = B + F_{\text{dec}}$

Posição	Conta	Resultado
(1,1)	$1.4627 + (0.7313)$	2.1940
(1,2)	$0.1409 + (0.0704)$	0.2113
(1,3)	$-1.3286 + (0.0000)$	-1.3286
(1,4)	$-0.2749 + (0.0000)$	-0.2749
(2,1)	$-0.3407 + (0.0000)$	-0.3407
(2,2)	$1.6350 + (0.8175)$	2.4525
(2,3)	$-1.0791 + (0.0000)$	-1.0791
(2,4)	$-0.2152 + (0.0000)$	-0.2152
(3,1)	$0.8411 + (0.4205)$	1.2616
(3,2)	$-1.0508 + (0.0000)$	-1.0508
(3,3)	$1.1456 + (0.5728)$	1.7185
(3,4)	$-0.9359 + (0.0000)$	-0.9359

Normalização para obter D - média e variância por token

Posição	Conta	Resultado
média 1	$\frac{(2.1940)+(0.2113)+(-1.3286)+(-0.2749)}{4}$	0.200439
var. 1	$(2.1940-(0.200439))^2+(0.2113-(0.200439))^2$ $+(-1.3286-(0.200439))^2+(-0.2749-(0.200439))^2$ Dividir a soma acima por 4.	1.634572
média 2	$\frac{(-0.3407)+(2.4525)+(-1.0791)+(-0.2152)}{4}$	0.204373
var. 2	$(-0.3407-(0.204373))^2+(2.4525-(0.204373))^2$ $+(-1.0791-(0.204373))^2+(-0.2152-(0.204373))^2$ Dividir a soma acima por 4.	1.793594
média 3	$\frac{(1.2616)+(-1.0508)+(1.7185)+(-0.9359)}{4}$	0.248338
var. 3	$(1.2616-(0.248338))^2+(-1.0508-(0.248338))^2$ $+(1.7185-(0.248338))^2+(-0.9359-(0.248338))^2$ Dividir a soma acima por 4.	1.569534

Normalização para obter D - cada componente normalizada

Posição	Conta	Resultado
(1,1)	$\frac{2.1940-(0.200439)}{\sqrt{1.634572+0.00001}}$	1.5593
(1,2)	$\frac{0.2113-(0.200439)}{\sqrt{1.634572+0.00001}}$	0.0085
(1,3)	$\frac{-1.3286-(0.200439)}{\sqrt{1.634572+0.00001}}$	−1.1960
(1,4)	$\frac{-0.2749-(0.200439)}{\sqrt{1.634572+0.00001}}$	−0.3718
(2,1)	$\frac{-0.3407-(0.204373)}{\sqrt{1.793594+0.00001}}$	−0.4070
(2,2)	$\frac{2.4525-(0.204373)}{\sqrt{1.793594+0.00001}}$	1.6786
(2,3)	$\frac{-1.0791-(0.204373)}{\sqrt{1.793594+0.00001}}$	−0.9583
(2,4)	$\frac{-0.2152-(0.204373)}{\sqrt{1.793594+0.00001}}$	−0.3133

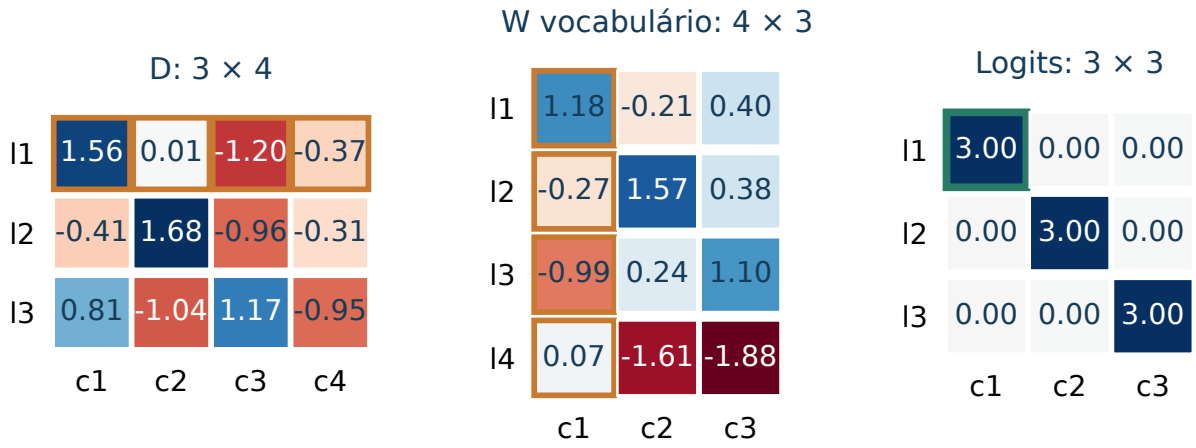
Continua na próxima página.

Posição	Conta (continuação)	Resultado
(3,1)	$\frac{1.2616-(0.248338)}{\sqrt{1.569534+0.00001}}$	0.8088
(3,2)	$\frac{-1.0508-(0.248338)}{\sqrt{1.569534+0.00001}}$	-1.0370
(3,3)	$\frac{1.7185-(0.248338)}{\sqrt{1.569534+0.00001}}$	1.1735
(3,4)	$\frac{-0.9359-(0.248338)}{\sqrt{1.569534+0.00001}}$	-0.9453

13. Transformando os vetores em probabilidades de palavras

Para que serve esta etapa? Transformar características internas em escores para os tokens do vocabulário e convertê-los em probabilidades. Cada coluna da projeção final está associada a um possível token de saída.

Dimensões. Aqui, $(3 \times 4)(4 \times 3) \to 3 \times 3$. Em aplicações reais, a projeção frequentemente amplia de centenas de componentes para milhares de tokens.



Leitura da imagem. A linha 1 de D é combinada com cada coluna de W para produzir os três logits da primeira previsão. O destaque mostra o logit de I.

Vamos limitar o vocabulário de saída a:

$$\mathcal{V} = [\text{I}, \text{study}, \langle \text{EOS} \rangle].$$

Precisamos transformar cada vetor de quatro componentes em três escores:

$$\Lambda = DW_{\text{vocab}} + b_{\text{vocab}}.$$

A matriz Λ contém os logits, os escores anteriores ao softmax. Usaremos $b_{\text{vocab}} = 0$ e:

$$W_{\text{vocab}} = \begin{bmatrix} 1.182910 & -0.207558 & 0.396954 \\ -0.265211 & 1.574028 & 0.376046 \\ -0.990779 & 0.239950 & 1.103583 \\ 0.073081 & -1.606420 & -1.876582 \end{bmatrix}.$$

Essa matriz foi escolhida para que o exemplo produza a sequência desejada. Em um treinamento real, seus valores seriam aprendidos a partir dos dados.

A multiplicação produz:

$$\Lambda \approx \begin{bmatrix} 3 & 0 & 0 \\ 0 & 3 & 0 \\ 0 & 0 & 3 \end{bmatrix}.$$

Aplicamos o softmax em cada linha:

$$P_{tj} = \frac{e^{\Lambda_{tj}}}{\sum_{r=1}^{3} e^{\Lambda_{tr}}}.$$

Por exemplo:

$$P(\text{I} \mid \langle\text{BOS}\rangle, \text{entrada}) = \frac{e^3}{e^3 + e^0 + e^0} \approx 0.9094.$$

A matriz de probabilidades é:

$$\boxed{P \approx \begin{bmatrix} 0.9094 & 0.0453 & 0.0453 \\ 0.0453 & 0.9094 & 0.0453 \\ 0.0453 & 0.0453 & 0.9094 \end{bmatrix}.}$$

As colunas seguem a ordem $[\text{I}, \text{study}, \langle\text{EOS}\rangle]$.

O que é um logit? É um escore real anterior à normalização. Pode ser negativo ou positivo e não precisa somar um valor específico. O softmax final usa todos os logits de uma linha para produzir uma distribuição de probabilidades sobre o vocabulário.

Reduzir ou ampliar depende das dimensões. No vocabulário reduzido deste exemplo, passamos de 4 componentes para 3 escores. Com um vocabulário de $30\,000$ tokens, a mesma função poderia transformar um vetor de 512 componentes em $30\,000$ escores.

Cálculos posição a posição

Nas tabelas, (i, j) indica linha i e coluna j. Os resultados usam os valores completos; pequenas diferenças ao refazer as contas com os números impressos decorrem do arredondamento.

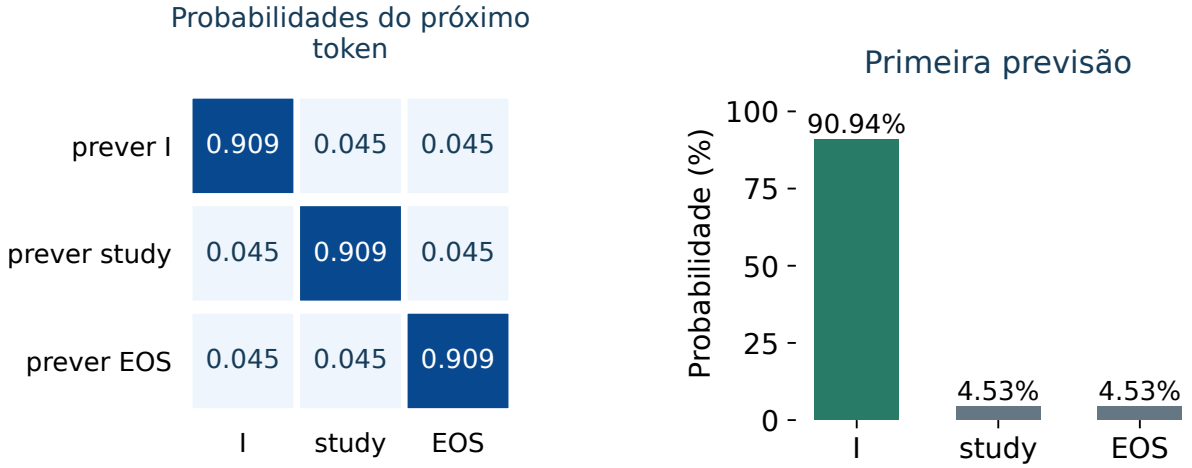
Agora, a linha i corresponde à previsão de um token; a coluna j corresponde a I, study ou EOS. Cada logit combina as quatro componentes de D com uma coluna de W_{vocab}.

Todos os logits: $\Lambda = DW_{\text{vocab}}$

Posição	Conta	Resultado
(1,1)	$(1.559274)(1.182910) + (0.008486)(-0.265211) + (-1.195967)(-0.990779) + (-0.371792)(0.073081)$	2.999999
(1,2)	$(1.559274)(-0.207558) + (0.008486)(1.574028) + (-1.195967)(0.239950) + (-0.371792)(-1.606420)$	-0.000001
(1,3)	$(1.559274)(0.396954) + (0.008486)(0.376046) + (-1.195967)(1.103583) + (-0.371792)(-1.876582)$	0.000001
(2,1)	$(-0.406981)(1.182910) + (1.678621)(-0.265211) + (-0.958343)(-0.990779) + (-0.313296)(0.073081)$	0.000000
(2,2)	$(-0.406981)(-0.207558) + (1.678621)(1.574028) + (-0.958343)(0.239950) + (-0.313296)(-1.606420)$	2.999999
(2,3)	$(-0.406981)(0.396954) + (1.678621)(0.376046) + (-0.958343)(1.103583) + (-0.313296)(-1.876582)$	0.000000
(3,1)	$(0.808776)(1.182910) + (-1.036965)(-0.265211) + (1.173463)(-0.990779) + (-0.945275)(0.073081)$	0.000000

Continua na próxima página.

Posição	Conta (continuação)	Resultado
(3,2)	$(0.808776)(-0.207558) + (-1.036965)(1.574028)$ $+(1.173463)(0.239950) + (-0.945275)(-1.606420)$	0.000001
(3,3)	$(0.808776)(0.396954) + (-1.036965)(0.376046)$ $+(1.173463)(1.103583) + (-0.945275)(-1.876582)$	3.000000



Leitura da imagem. O softmax final transforma logits em probabilidades sobre o vocabulário. Na primeira previsão, I recebe aproximadamente 90.94%.

Softmax final sobre o vocabulário - denominador de cada linha

Posição	Conta	N_i
linha 1	$e^{3.0000} + e^{0.0000} + e^{0.0000}$	22.0855
linha 2	$e^{0.0000} + e^{3.0000} + e^{0.0000}$	22.0855
linha 3	$e^{0.0000} + e^{0.0000} + e^{3.0000}$	22.0855

Softmax final sobre o vocabulário - cada peso

Posição	Conta	Resultado
(1,1)	$\frac{e^{3.0000}}{22.0855}$	0.9094
(1,2)	$\frac{e^{0.0000}}{22.0855}$	0.0453
(1,3)	$\frac{e^{0.0000}}{22.0855}$	0.0453

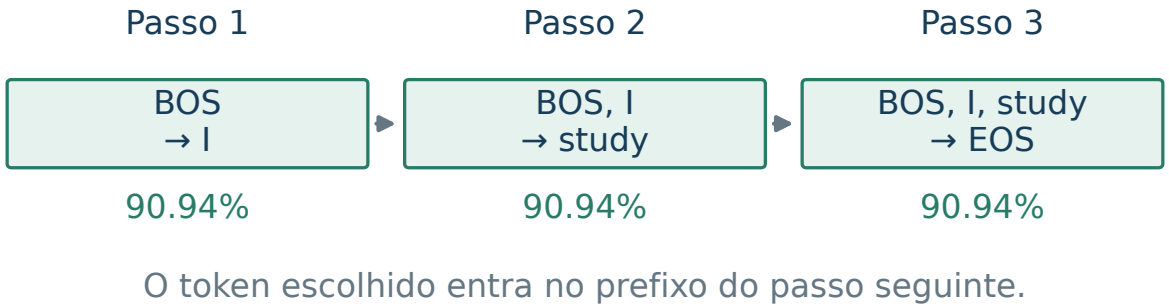
Continua na próxima página.

Posição	Conta (continuação)	Resultado
(2,1)	$\frac{e^{0.0000}}{22.0855}$	0.0453
(2,2)	$\frac{e^{3.0000}}{22.0855}$	0.9094
(2,3)	$\frac{e^{0.0000}}{22.0855}$	0.0453
(3,1)	$\frac{e^{0.0000}}{22.0855}$	0.0453
(3,2)	$\frac{e^{0.0000}}{22.0855}$	0.0453
(3,3)	$\frac{e^{3.0000}}{22.0855}$	0.9094

14. Gerando a tradução em sequência

Para que serve esta etapa? Escolher o próximo token e usá-lo como parte do prefixo da previsão seguinte. A geração é sequencial: I entra no contexto usado para prever study; depois study entra no contexto usado para prever EOS.

Dimensões. Cada passo escolhe uma das 3 categorias. A memória do codificador é reutilizada; o prefixo do decodificador cresce.



Leitura da imagem. O codificador é reutilizado. O prefixo do decodificador cresce até que o token EOS seja escolhido.

Escolheremos o token de maior probabilidade em cada passo:

$$\hat{y}_t = \arg\max_j P_{tj}.$$

Essa estratégia é chamada de decodificação gulosa, ou *greedy decoding*.

Passo	Prefixo disponível	Escolha	Probabilidade
1	⟨BOS⟩	I	90,94%
2	⟨BOS⟩, I	study	90,94%
3	⟨BOS⟩, I, study	⟨EOS⟩	90,94%

Ao produzir ⟨EOS⟩, encerramos:

$$\boxed{\text{I study}}.$$

Na geração, o segundo passo depende do token escolhido no primeiro. No treinamento, podemos fornecer os tokens corretos deslocados e calcular as posições em paralelo, mantendo a máscara causal.

Foi conferido numericamente que calcular cada prefixo separadamente reproduz a mesma linha mostrada no cálculo conjunto.

A página também apresenta a busca em feixe, ou *beam search*, que mantém várias sequências candidatas. A pontuação probabilística de uma sequência pode ser escrita como:

$$\log P(y_1, \ldots, y_m \mid x) = \sum_{t=1}^{m} \log P(y_t \mid y_{<t}, x).$$

Aqui utilizamos apenas a escolha gulosa.

Treinamento e geração. Durante o treinamento, os prefixos corretos podem ser fornecidos de uma vez e a máscara controla o acesso a eles. Durante a geração, o prefixo é construído com os tokens que o próprio modelo escolhe. Se a primeira escolha mudar, o contexto dos passos seguintes também muda.

Cálculos posição a posição

Nas tabelas, (i, j) indica linha i e coluna j. Os resultados usam os valores completos; pequenas diferenças ao refazer as contas com os números impressos decorrem do arredondamento.

As três decisões usam a mesma regra.

$$\begin{aligned}\hat{y}_1 &= \arg\max[0.9094, 0.0453, 0.0453] = \text{I},\\ \hat{y}_2 &= \arg\max[0.0453, 0.9094, 0.0453] = \text{study},\\ \hat{y}_3 &= \arg\max[0.0453, 0.0453, 0.9094] = \langle\text{EOS}\rangle.\end{aligned}$$

A probabilidade condicional da sequência gerada é o produto das três probabilidades selecionadas:

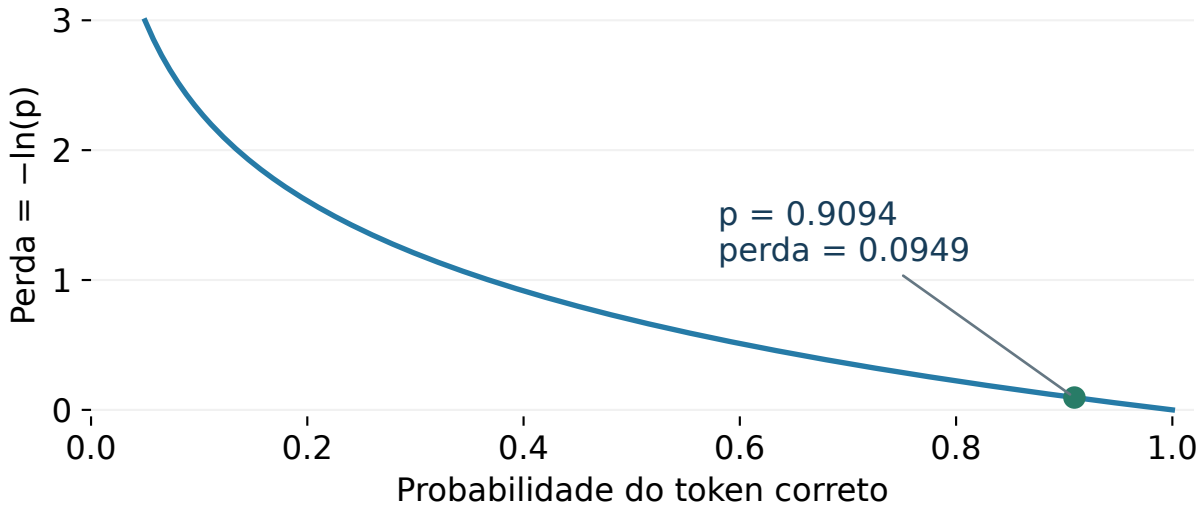
$$P(\text{I, study, }\langle\text{EOS}\rangle \mid \text{eu estudo}) \approx 0.909443 \times 0.909443 \times 0.909443.$$

Essa conta reúne as probabilidades de uma sequência; a perda média da próxima etapa usa seus logaritmos.

15. Calculando a perda com os mesmos dados

Para que serve esta etapa? Medir quanto o modelo favoreceu os tokens corretos. A entropia cruzada usa o logaritmo da probabilidade atribuída ao alvo de cada posição e calcula a média das perdas das três previsões.

Dimensões. Uma matriz de probabilidades 3×3 é comparada a alvos 3×3, produzindo um único número: a perda média.



Leitura da imagem. Quanto maior a probabilidade do token correto, menor a perda. O ponto destacado é o resultado do mesmo exemplo usado em todas as etapas.

A sequência correta é $[\text{I}, \text{study}, \langle\text{EOS}\rangle]$. Na ordem do nosso vocabulário, os alvos one-hot são:

$$Y = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}.$$

Usando entropia cruzada sem suavização dos alvos:

$$\mathcal{L} = -\frac{1}{m} \sum_{t=1}^{m} \sum_{j=1}^{|\mathcal{V}|} Y_{tj} \log P_{tj}.$$

Como cada linha de Y contém um único valor 1:

$$\mathcal{L} = -\frac{1}{3} \left[\log P_{1,\text{I}} + \log P_{2,\text{study}} + \log P_{3,\text{EOS}} \right].$$

Substituindo as probabilidades calculadas:

$$\mathcal{L} \approx -\frac{1}{3} [\log(0.909443) + \log(0.909443) + \log(0.909443)].$$

Portanto:

$$\boxed{\mathcal{L} \approx 0.094923.}$$

Essa perda diminui conforme aumenta a probabilidade atribuída aos tokens corretos. O logaritmo é natural, de modo que a perda está expressa em nats por token.

Por que a perda ainda é positiva quando a palavra escolhida está correta? Escolher a categoria de maior probabilidade acerta o token deste exemplo, mas o modelo atribuiu cerca de 90.94% ao alvo, e não 100%. A entropia cruzada continua quantificando essa diferença de confiança.

Cálculos posição a posição

Nas tabelas, (i, j) indica linha i e coluna j. Os resultados usam os valores completos; pequenas diferenças ao refazer as contas com os números impressos decorrem do arredondamento.

Perda de cada posição correta

Posição	Conta	Resultado
linha 1	$-\ln(0.909443)$	0.094923
linha 2	$-\ln(0.909443)$	0.094923
linha 3	$-\ln(0.909443)$	0.094923

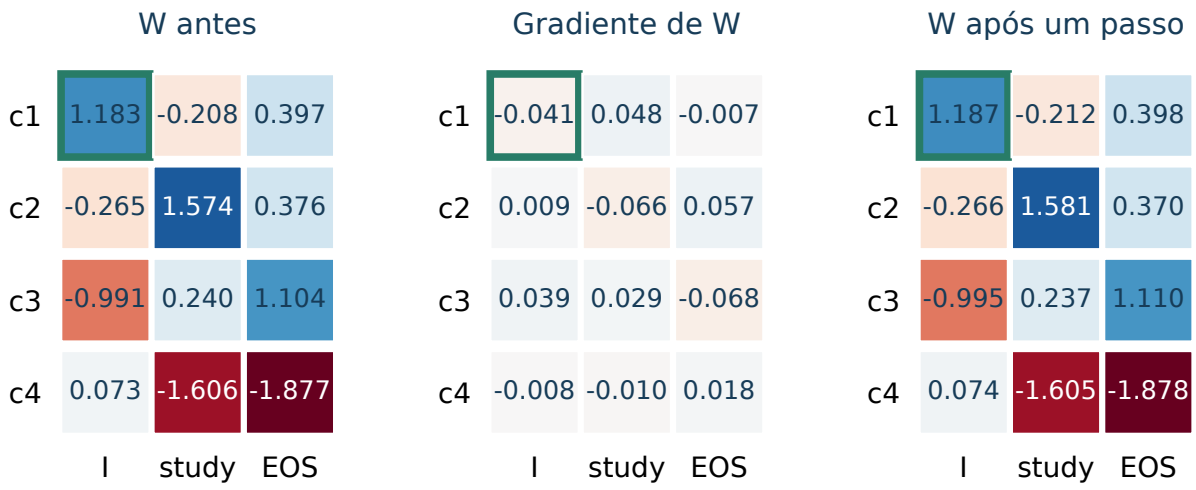
Média das três posições.

$$\mathcal{L} = \frac{0.094923 + 0.094923 + 0.094923}{3} \approx 0.094923.$$

16. Como essa perda modifica os pesos

Para que serve esta etapa? Determinar como os parâmetros devem mudar para reduzir a perda. A regra da cadeia relaciona o erro nas probabilidades aos logits e à matriz de projeção. Nesta demonstração, detalhamos todas as células do gradiente dessa matriz e um passo de atualização.

Dimensões. O gradiente dos logits é 3×3. Multiplicar por $D^\top$ produz um gradiente 4×3, com o mesmo formato de W_{vocab}.



Leitura da imagem. A atualização usa Wnovo = Wantigo − 0.1 × gradiente. O primeiro peso passa de 1.182910 para aproximadamente 1.187010.

Com softmax e entropia cruzada média, o gradiente em relação aos logits é:

$$\boxed{\frac{\partial \mathcal{L}}{\partial \Lambda} = \frac{P - Y}{3}.}$$

No nosso exemplo:

$$\frac{\partial \mathcal{L}}{\partial \Lambda} \approx \begin{bmatrix} -0.030186 & 0.015093 & 0.015093 \\ 0.015093 & -0.030186 & 0.015093 \\ 0.015093 & 0.015093 & -0.030186 \end{bmatrix}.$$

Como $\Lambda = DW_{\text{vocab}}$, a regra da cadeia fornece:

$$\frac{\partial \mathcal{L}}{\partial W_{\text{vocab}}} = D^\top \frac{\partial \mathcal{L}}{\partial \Lambda}.$$

Para o primeiro peso da matriz:

$$\frac{\partial \mathcal{L}}{\partial W_{\text{vocab},11}} \approx -0.041004.$$

Um passo de descida do gradiente seria:

$$W_{\text{novo}} = W_{\text{antigo}} - \eta \frac{\partial \mathcal{L}}{\partial W}.$$

Com taxa de aprendizagem $\eta = 0.1$:

$$\begin{aligned} W^{\text{novo}}_{\text{vocab},11} &= 1.182910 - 0.1(-0.041004) \\ &\approx 1.187010. \end{aligned}$$

Mostramos a atualização de um peso. A retropropagação continua pela rede, calculando também os gradientes dos pesos de atenção, das redes feed-forward, das normalizações e dos embeddings.

Todo esse cálculo utilizou o mesmo par:

eu estudo $\longrightarrow$ I study.

Como interpretar os sinais. Um gradiente negativo em relação ao logit correto indica que aumentá-lo tende a reduzir a perda. Nos pesos, o sinal também depende das componentes de D, que podem ser positivas ou negativas.

Escopo da atualização mostrada. As tabelas abaixo calculam um passo simples de descida do gradiente para todas as células de W_{vocab}, usando a mesma passagem direta. Um treinamento completo também ajustaria os demais parâmetros por retropropagação.

Cálculos posição a posição

Nas tabelas, (i, j) indica linha i e coluna j. Os resultados usam os valores completos; pequenas diferenças ao refazer as contas com os números impressos decorrem do arredondamento.

Cada célula de $\partial\mathcal{L}/\partial\Lambda$

Posição	Conta	Resultado
(1,1)	$\frac{0.909443 - 1}{3}$	-0.030186
(1,2)	$\frac{0.045279 - 0}{3}$	0.015093
(1,3)	$\frac{0.045279 - 0}{3}$	0.015093
(2,1)	$\frac{0.045279 - 0}{3}$	0.015093
(2,2)	$\frac{0.909443 - 1}{3}$	-0.030186
(2,3)	$\frac{0.045279 - 0}{3}$	0.015093
(3,1)	$\frac{0.045278 - 0}{3}$	0.015093

Continua na próxima página.

Posição	Conta (continuação)	Resultado
(3,2)	$\frac{0.045279 - 0}{3}$	0.015093
(3,3)	$\frac{0.909443 - 1}{3}$	-0.030186

Na tabela seguinte, a linha do gradiente de W corresponde a uma das quatro componentes internas; a coluna corresponde a um token do vocabulário.

Gradiente de todos os pesos: $D^\top(P - Y)/3$

Posição	Conta	Resultado
(1,1)	$(1.559274)(-0.030186) + (-0.406981)(0.015093)$ $+(0.808776)(0.015093)$	-0.041004
(1,2)	$(1.559274)(0.015093) + (-0.406981)(-0.030186)$ $+(0.808776)(0.015093)$	0.048026
(1,3)	$(1.559274)(0.015093) + (-0.406981)(0.015093)$ $+(0.808776)(-0.030186)$	-0.007022
(2,1)	$(0.008486)(-0.030186) + (1.678621)(0.015093)$ $+(-1.036965)(0.015093)$	0.009428
(2,2)	$(0.008486)(0.015093) + (1.678621)(-0.030186)$ $+(-1.036965)(0.015093)$	-0.066193
(2,3)	$(0.008486)(0.015093) + (1.678621)(0.015093)$ $+(-1.036965)(-0.030186)$	0.056765
(3,1)	$(-1.195967)(-0.030186) + (-0.958343)(0.015093)$ $+(1.173463)(0.015093)$	0.039348
(3,2)	$(-1.195967)(0.015093) + (-0.958343)(-0.030186)$ $+(1.173463)(0.015093)$	0.028589
(3,3)	$(-1.195967)(0.015093) + (-0.958343)(0.015093)$ $+(1.173463)(-0.030186)$	-0.067936
(4,1)	$(-0.371792)(-0.030186) + (-0.313296)(0.015093)$ $+(-0.945275)(0.015093)$	-0.007773
(4,2)	$(-0.371792)(0.015093) + (-0.313296)(-0.030186)$ $+(-0.945275)(0.015093)$	-0.010421
(4,3)	$(-0.371792)(0.015093) + (-0.313296)(0.015093)$ $+(-0.945275)(-0.030186)$	0.018194

Um passo de atualização em toda a matriz de projeção

Posição	Conta	Resultado
(1,1)	$1.182910 - 0.1(-0.041004)$	1.187010
(1,2)	$-0.207558 - 0.1(0.048026)$	-0.212361
(1,3)	$0.396954 - 0.1(-0.007022)$	0.397656
(2,1)	$-0.265211 - 0.1(0.009428)$	-0.266154
(2,2)	$1.574028 - 0.1(-0.066193)$	1.580647
(2,3)	$0.376046 - 0.1(0.056765)$	0.370370
(3,1)	$-0.990779 - 0.1(0.039348)$	-0.994714
(3,2)	$0.239950 - 0.1(0.028589)$	0.237091
(3,3)	$1.103583 - 0.1(-0.067936)$	1.110377
(4,1)	$0.073081 - 0.1(-0.007773)$	0.073858
(4,2)	$-1.606420 - 0.1(-0.010421)$	-1.605378
(4,3)	$-1.876582 - 0.1(0.018194)$	-1.878401

Matriz resultante após esse passo:

$$W_{\text{vocab}}^{\text{novo}} \approx \begin{bmatrix} 1.187010 & -0.212361 & 0.397656 \\ -0.266154 & 1.580647 & 0.370370 \\ -0.994714 & 0.237091 & 1.110377 \\ 0.073858 & -1.605378 & -1.878401 \end{bmatrix}.$$

Esse passo de atualização usa apenas a matriz de projeção final para tornar a regra verificável. Os diagramas e todas as contas anteriores correspondem à passagem direta com os pesos originais, antes dessa atualização.

Referências e atribuição

[1] ALAMMAR, Jay. *The Illustrated Transformer*. 2018. Disponível em: https://jalammar.github.io/illustrated-transformer/.

[2] VASWANI, Ashish et al. *Attention Is All You Need*. 2017. arXiv:1706.03762. Disponível em: https://arxiv.org/abs/1706.03762.

[3] BA, Jimmy Lei; KIROS, Jamie Ryan; HINTON, Geoffrey E. *Layer Normalization*. 2016. arXiv:1607.06450. Disponível em: https://arxiv.org/abs/1607.06450.

Licença e alterações. Adaptação de *The Illustrated Transformer*, de Jay Alammar, com tradução explicativa dos conceitos, reorganização, diagramas originais e exemplo numérico detalhado célula a célula. Esta adaptação é disponibilizada sob a mesma licença do artigo: CC BY-NC-SA 4.0 (Atribuição, NãoComercial e CompartilhaIgual). O link dá acesso às condições completas da licença.